

실시간 기반 폭행-실신 감지 및 자연어 보고 순찰 드론

김유나, 정현욱, 이성진, 김현서, 정은성

홍익대학교 소프트웨어융합학과 소속

e-mail : rladbsk2805@naver.com, ppid0930@naver.com, sjlee7485@naver.com,
gustj97613@g.hongik.ac.kr, ejung@hongik.ac.kr

Real-Time Assault and Fainting Detection and Reporting Patrol Drone Using a Vision-Language Model

Yuna Kim , Hyunwook Jeong, Seongjin Lee, Hyeonseo Kim, Eunsung Jeong
Hongik University

Abstract

This study presents an AI-based autonomous patrol drone system capable of real-time detection and natural language reporting of abnormal situations such as assault and fainting. The drone autonomously flies along predefined routes and performs on-device behavior classification using a lightweight model deployed on the Jetson platform. When an abnormal situation is detected, the corresponding video clip is transmitted to the server, where a Vision-Language Model (VLM) automatically generates a detailed textual description of the event. This enables the central administrator to quickly understand the situation and take immediate action. The implemented system achieved stable autonomous navigation and approximately 98% accuracy in abnormal behavior classification, while the VLM produced accurate and contextually appropriate descriptions. Overall, this research proposes a practical and scalable framework for real-time aerial surveillance and response, demonstrating the potential of AI-powered patrol drones as next-generation public safety platforms.

I. 서론

현재 대한민국에서는 폭행, 실신, 흉기 난동 등 예측 불가능한 사건이 잇따라 발생하고 있다. 2023년 7월 서울 신림역 흉기 난동 사건 [1]은 실시간 대응 체계의 부재가 인명 피해로 직결될 수 있음을 보여주며, 지속적으로 불특정 다수를 대상으로 한 묻지마 범죄가 지속적으로 발생하여 시민들이 불안감을 느끼고 있다 [2]. 이와 더불어 의식 상실 상태의 시민이 즉시 발견되지 못해 골든타임을 놓치는 사례 역시 반복적으로 발생하고 있다 [3]. 또한, 산업 시설, 공항, 병원 등 여전히 CCTV와 인력 순찰 중심의 보안 체계에 의존하고 있으나, CCTV는 설치 위치에 따른 시야 한계와 단순 기록 기능에 머물러 폭행, 실신 등 이상 상황을 즉각적으로 인식하기 어렵다. 관리자 역시 화면만으로는 이 상황의 맥락과 피해자 상태를 정확히 파악하기 힘들어, 초기 대응 지연의 문제가 발생한다.

이러한 한계를 보완하기 위해 본 프로젝트는 AI 기반의 실시간 폭행-실신 감지 및 자연어 상황 보고 기능을 통합한 자율 순찰 드론 시스템을 제안한다. 드론의 기동성과 상황 판단 분류 모델, 언어적 표현 능력으로 상황 설명이 가능한 VLM을 결합하여, 이상행동을 실시간으로 탐지하고, 이를 사람이 즉시 이해할 수 있는 자연어 형태로 보고한다. 제안한 시스템의 주요 구성 요소는 다음과 같다.

1. 자율 순찰 드론 : 자율적으로 사전 경로를 따라 비행하며, 배터리 및 위치 정보를 실시간 모니터링 한다.
2. 온디바이스 이상행동 탐지 : 드론에 탑재하는 Jetson에 탑재된 분류 모델로 정상, 폭행, 실신을 실시간으로 분류하며, 이상행동이 감지된 경우에만 해당 영상과 결과를 서버로 전송한다
3. VLM을 통한 상황 설명 : 감지된 영상을 분석해 상황 설명 자연어를 생성한다.
4. 실시간 대응 체계 : 탐지 결과와 텍스트가 중앙 관리자에게 전송되어, 영상-텍스트 기반 판단 및 신고 결정이 가능하다.

II. 본론

2.1 관련 연구

2.1.1 이상행동 감지

이상행동 감지는 영상 내에서 폭행, 실신, 절도 등과 같은 비정상적인 행동을 인식하는 기술로, 공공안전 및 감시 분야에서 활발히 연구되고 있다.

Carreira와 Zisserman(2017)은 2D CNN을 3D로 확장한 I3D 모델을 제안하여 시공간 정보를 통합적으로 학습함으로써 행동 인식 성능을 향상시켰다 [4]. Feichtenhofer 등(2019)은 서로 다른 시간 해상도의 두 스트림을 결합한 SlowFast Network를 통해 느린·빠른 움직임을 동시에 포착하였다 [5]. 이처럼 영상을 기반으로 이상행동 감지 연구가 활발히 진행되고 있다.

2.1.2 VLM 기반 상황 설명

Vision-Language Model(VLM)은 시각적 입력(이미지, 영상)을 언어적 표현으로 변환하는 멀티모달 인공지능 모델로, CLIP [6], LLaVA [7], Qwen-VL [8] 등 최근 영상 요약 및 자동 보고 분야에서 주목받고 있다.

2.1.3 드론 기반 AI 시스템

드론은 높은 기동성과 넓은 시야 확보 능력을 바탕으로 공공 안전, 재난 감시, 교통 관리 등 다양한 분야에 활용되고 있다. Kyrkou 등(2018)은 드론 탑재용 실시간 CNN 모델을 제안하며, 본 모델을 통해 차량 또는 객체를 탐지함을 제안한다 [9]. 또한 Chen 등(2021) [10] 와 같이 다양한 드론을 기반으로 AI를 결합하여 객체 탐지를 하는 연구가 활발히 진행되고 있다.

2.1.4 본 연구의 차별점

기존 연구들은 이상행동 감지, 객체 탐지, 재난 인식 등 단일 기능 중심의 접근이 대부분으로, 복합적 상황의 이해나 실시간 대응 체계 구축에는 한계가 있었다. 특히 드론 기반 연구들은 실시간 영상

분석이나 객체 탐지에 초점을 맞추어, 탐지 결과를 언어적으로 해석·보고하는 지능형 순찰 체계로 발전하지는 못하였다.

이에 본 연구는 실시간 폭행·실신 감지와 자연어 보고 기능을 통합한 자율 순찰 드론 시스템을 제안한다. 드론은 사전 경로에 따라 자율 비행하며, 탑재된 Jetson 기반 분류 모델이 온디바이스에서 이상행동을 실시간 탐지한다. 감지된 상황은 서버의 VLM을 통해 자연어로 해석되어 관리자에게 전달되며, 이를 통해 영상과 텍스트를 결합한 신속한 대응 체계를 구현하였다.

결과적으로 본 연구는 드론 자율 주행-이상행동 감지-자연어 보고를 통합한 지능형 순찰 프레임워크를 실현함으로써 기존 연구 대비 명확한 차별성을 가진다.

2.2 분류 모델 (TimeSformer)

본 연구에서는 Jetson Xavier NX 환경에서 실시간 온디바이스 추론이 가능한 경량 영상 분류 모델로 TimeSformer(Time-Space Transformer) [11]를 사용하였다. 기존 영상 분류는 단일 프레임에 적용된 2D CNN을 확장하여 프레임 간 시간적 관계를 학습하는 3D ConvNet을 사용해왔으나, 장기 의존성(Long-term dependency) 학습이 어렵고 연산량이 커 실시간 처리에 부적합하였다. 이를 해결하기 위해 도입된 Attention 메커니즘은 CNN의 지역적 한계를 극복하고, 전역적 문맥 정보를 학습할 수 있어 공간적·시간적 관계를 병렬적으로 모델링하는데 효과적이다.

이러한 구조를 영상 데이터에 특화시킨 모델이 TimeSformer로, Vision Transformer(ViT)를 확장하여 self-attention을 공간적(Spatial) 및 시간적(Temporal) 영역으로 분리해 적용한다. 입력 영상은 224×224 해상도로 리사이즈 후 패치 단위로 나누어 임베딩한 뒤, Temporal과 Spatial Attention을 순차적으로 수행함으로써 연산 효율성과 장기 의존성 학습 능력을 동시에 확보한다.

TimeSformer는 동시기 모델인 Video Swin Transformer [12] 대비 약 50% 적은 연산량으로 유사한 정확도를 보여 임베디드 GPU 환경에 적합하다. 이를 통해 Jetson Xavier NX 환경에서도 실시간 이상 행동 분류가 가능함을 확인하였다.

2.3 VLM (Qwen2.5-VL)

본 연구에서는 드론이 촬영한 영상으로부터

이상행동을 인식하고 이상행동을 수행하는 객체의 인상착의를 자연어로 기술하기 위해 Vision-Language Model(VLM)로 Qwen2.5-VL [13]을 채택하였다. Qwen2.5-VL은 video-text to text 태스크에서 최고 수준의 성능을 보이는 모델로 기존 공개 모델 대비 우수한 맥락 이해 및 시각적 서술 능력을 입증하였다. 이는 폭행이나 실신과 같은 이상행동을 정확히 인식하고 상황에 맞는 텍스트 보고문을 생성해야 하는 본 연구의 목적에 부합한다. 모델은 시각적 입력과 언어적 출력을 단일 Transformer 백본 내에서 통합적으로 처리하는 통합 비전-언어 구조(Unified Vision-Language Architecture)를 채택하여, 영상 프레임 간의 시간적 상관관계를 정교하게 반영할 수 있다. 또한 대규모 이미지-비디오-텍스트 데이터셋으로 사전 학습되어 다양한 객체 및 인물 행위에 대한 정교한 표현 능력을 갖추었으며 오픈소스로 공개되어 도메인별 데이터에 맞춘 미세조정(fine-tuning)에도 용이하다. 이러한 이유로 본 연구의 실시간 드론 기반 이상행동 탐지 및 상황 보고 시스템에 가장 적합한 VLM으로 판단되어 선정되었다. 해당 모델은 다양한 크기의 모델을 제안하고 있는데 그중에서 추론 속도와 하드웨어 환경에 맞춰서 Qwen2.5-VL-3B-Instruct [14] 모델을 최종 선정하였다.

2.4 통신 및 웹 서비스 구성

본 시스템은 드론(Pixhawk)-Jetson-Server-Front 간 실시간 데이터 흐름을 안정적으로 유지하도록 설계되었다.

Pixhawk는 MAVLink 프로토콜을 통해 Jetson과 유선으로 연결되어 비행 제어 정보를 교환하며, Jetson은 HTTP 요청을 통해 서버와 영상 및 이벤트 데이터를 송수신한다.

웹 서비스는 FastAPI와 Spring Boot 기반으로 AI 제어와 운영 기능을 분리하여 안정성과 확장성을 확보하였다. FastAPI는 Jetson으로부터의 이상행동 클립 수신, VLM 추론 등 AI 제어 기능을 담당하며, 비동기 구조를 통해 고성능 실시간 처리를 지원한다. Spring Boot는 사용자 인증, 알림, 데이터 관리 및 로그 기능을 담당하며, FastAPI로부터 전달된 결과를 관리자 콘솔로 전송한다.

프론트엔드(React)는 드론 위치·상태 모니터링, 영상 스트리밍, 이상행동 보고 등 관제 기능을 제공하며, Nginx를 통해 정적 자원 서빙과 HTTPS, 캐싱을 처리하여 응답 속도를 향상시켰다.

이러한 통합 구조를 통해 이상행동 탐지-상황 설명-의

사결정의 전 과정을 실시간으로 지원하는 효율적 관리 환경을 구현하였다.

2.5 Drone

본 연구에서는 HOLYBRO X650 드론을 기반으로, Pixhawk 6X 비행제어기와 PX4 MAVSDK를 적용하여 시스템을 구성하였다. PX4는 모듈식 RTOS 구조를 통해 센서 제어, 통신, 비상 대응을 독립적으로 처리하며, GPS 정밀 추정과 Fail-safe 기능으로 안정적인 비행을 지원한다. 기체의 최대 이륙중량은 약 6kg으로, 배터리 포함 3.5kg을 제외한 2.5kg의 유효 탑재 중량을 확보하여 Jetson 모듈, 카메라, 통신 장비 등을 안정적으로 장착할 수 있다. 시스템은 비행 제어(PX4/Pixhawk)와 영상 인식(Jetson)을 분리한 이중 구조로 설계되었다.

Jetson은 MAVLink를 통해 상태 정보를 Spring 서버로 전송하고, 이상행동(폭행·실신) 발생 시 해당 영상 클립을 FastAPI 기반 VLM 서버로 전달한다. 이를 통해 실시간 이상 상황 전송과 임무 종료 후 전체 영상 백업이 병행되는 이중 파이프라인을 구현하였다.

III. 구현

3.1 데이터셋

본 연구에서는 AI Hub 이상행동 CCTV 영상 데이터셋 [15]을 활용하였다. 해당 데이터셋은 폭행, 실신, 절도 등 12종의 이상행동을 포함한다. 이 중 본 연구는 폭행과 실신 두 유형을 대상으로 하였으며, 정상 클래스는 각 영상에서 이상행동이 발생하기 전 구간을 분리하여 구성하였다. 최종 데이터는 정상 3,475개, 폭행 1,162개, 실신 179개, 총 4,816개 영상 클립으로 구성했다.

3.2 분류 모델 구현 및 성능 실험

본 연구의 온디바이스 실험은 NVIDIA Jetson Xavier NX Developer Kit 환경에서 수행되었다. 해당 장치는 384-core Volta GPU (48 Tensor Cores)와 6-core Carmel ARMv8.2 CPU, 그리고 8GB LPDDR4x 메모리를 탑재하고 있다. 실험은 Ubuntu 20.04 (JetPack 5.1.5) 운영체제 환경에서 수행되었으며, CUDA 11.4와 TensorRT 8.5.2.2, Python 3.8.10, PyCUDA 2025.1.2 라이브러리를 활용하여 환경을 구성하였다.

모델 학습은 CentOS 7.9 운영체제, NVIDIA RTX 6000 Ada Generation (48GB VRAM) GPU와 251GB RAM을 사용하는 고성능 서버에서 수행되었다. Adam 옵티마이저를 사용하였고, learning rate

1e-6, batch size 8, epoch 2로 설정하여 모델을 학습시켰다.

표 1. 분류 모델 평가 결과

Table 1. Classification model evaluation results

Class/Metrics	Precision	Recall	F1-Score	Sample Count
Assault	0.9580	0.9913	0.9744	115
Normal	0.9971	1.0000	0.9986	348
Swoon	1.0000	0.7222	0.8387	18
Overall Accuracy	-	-	0.9875	-

분류 모델은 세 가지 클래스(Normal, Assault, Swoon)에 대해 학습 및 평가를 수행하였다. 테스트 데이터셋은 Assault 115개, Normal 348개, Swoon 18개로 구성되었으며, 각 클래스별 정밀도(Precision), 재현율(Recall), 그리고 F1-score를 산출하였다. 표 1을 확인하면, 모델의 전체 정확도(Overall Accuracy)는 0.9875로 나타났으며, 이는 대부분의 테스트 영상에 대해 정상적으로 행동 유형을 분류함을 의미한다. 5초 길이의 입력 영상의 중앙 2초구간을 전처리한 후 모델에 입력하였으며, 평균 추론 시간은 1.3초로 실시간 대응이 가능한 수준이다.

3.3 VLM 모델 구현 및 성능 실험

본 연구에서는 Qwen2.5-VL-3B-Instruct를 기반으로 폭행 및 실신 행위를 포함한 이상행동 영상 데이터셋을 이용하여 미세조정을 수행하였다. 이후 동일한 영상에 대해 미세조정된 모델과 사전 학습 원본 모델의 추론 결과를 비교함으로써 미세조정의 효과를 분석하였다. 평가에는 본 연구에서 구축한 이상행동 영상 데이터셋 중 일부를 사용하였다. 폭행의 경우, 각 세부 유형별로 대표 영상 1개씩을 선정하였으며 실신의 경우 총 5개의 영상을 활용하였다.

모델의 출력 결과는 구성된 Ground Truth(GT)와의 일치 여부를 기반으로 인상착의 표현과 행동 대분류의 두 항목에서 평가하였다. 평가 척도는 세 등급으로 구분하였으며 각 기준은 다음과 같다.

인상착의 표현(Clothing Description)의 평가는 다음과 같이 수행하였다. 정확은 착의 색상과 형태가 GT와 완전히 일치하거나 동등한 경우로 정의하였다. 근접은 색상의 차이는 있으나 유사한 색상을 언급한 경우(예: 검은색을 회색으로 응답한 경우)를 의미한다. 불일치는 착의 정보가 GT와 상반되거나 제대로 반영되지 않은 경우로 평가하였다.

행동 대분류(Action Type Classification)의 경우, 정확은 GT의 대분류(폭행/실신)와 일치하며 문맥적으로 명확히 표현한 경우, 불일치는 GT와 상반되거나 일반 행위로 서술된 경우로 평가하였다.

표 2. Fine-tuned VLM 모델 평가 결과

Table 2. VLM model evaluation results

Metrics	Fine-tuned Model			
	정확	근접	불일치	정확+근접
Clothing Description	36.4%	54.5%	9.1%	90.9%
Action Type Classification	90.9%	-	9.1%	90.9%
Action Type Classification (Assault only)	100.0%	-	0.0%	100.0%
Action Type Classification (Swoon only)	80.0%	-	20.0%	80.0%

표 3. Base VLM 모델 평가 결과

Table 3. Base VLM model evaluation results

Metrics	Base Model			
	정확	근접	불일치	정확+근접
Clothing Description	9.1%	72.7%	18.2%	81.8%
Action Type Classification	63.6%	-	36.4%	63.6%
Action Type Classification (Assault only)	33.3%	-	66.7%	33.3%
Action Type Classification (Swoon only)	100.0%	-	0.0%	100.0%

실험 결과, 표 1에서 분류 모델은 98.75%의 정확도를 기록하였다. 또한, 미세조정된 VLM은 표 2와 같이 인상착의 표현(정확+근접)에서 90.9%, 행동 분류에서 90.9%의 정확도를 보이며 맥락적 설명 능력에서도 우수한 성능을 입증하였다. 행동 분류 평가에서도 약 27.3% 향상되었으며 폭행 장면은 모두 명확히 인식한 반면, 실신 구간에서는 미세 조정된 모델이 Base 모델 대비 정확도 저하가 나타났다. 이는 실신 데이터의 불균형으로 판단된다.

표 1의 분류 모델 결과와 표 3의 Base VLM 결과를 보면, Jetson 기반 분류기의 높은 정확도가 VLM 입력 품질을 보장해 전반적인 추론 정확도가 유지됨을 확인할 수 있다. 그러나 Base VLM은 81.8%, 63.6%의 정확도에 그치고 폭행 행위 인식에서는 낮은 성능을 보였다. 이에 따라 Fine-tuning을 수행한 모델(표 2)은 행동 인식 정확도를 크게 향상 시켜, 표 1과 표 2가 상호 보완적으로

작용함을 입증하였다.

IV. 결론 및 향후 연구 방향

본 연구는 실시간 폭행·실신 감지 및 자연어 보고 기능을 통합한 자율 순찰 드론 시스템을 구현하였다. 드론은 자율 비행을 통해 영상을 수집하고, Jetson 기반 TimeSformer 분류 모델로 온디바이스 이상행동 탐지를 수행한다. 탐지된 영상은 서버로 전송되어 Qwen2.5-VL 기반 VLM이 상황을 자연어로 기술함으로써, 관리자는 즉각적인 대응 결정을 내릴 수 있다.

본 연구는 실시간 감시 및 대응을 위한 실용적이고 확장 가능한 프레임워크를 제시하며, AI 기반 순찰 드론이 차세대 공공 안전 플랫폼으로 발전할 가능성을 보여준다.

참고문헌

- [1] 연합뉴스, "신림역 흉기난동...서울 관악구 신림동서 30대 남성 흉기 휘둘러," 연합뉴스, 2023. 7. 21. [Online]. Available: <https://www.yna.co.kr/view/AKR20230726118900004>
- [2] 시사저널, "'묻지마 흉기난동' 이후 불안에 떠는 시민들," 시사저널, 2023. 8. 10. [Online]. Available: <https://www.sisajournal.com/news/articleView.html?idxno=338077>
- [3] 월간조선, "의식 잃은 시민 방치... 골든타임 놓쳐," 월간조선, 2008. 7. [Online]. Available: <https://monthly.chosun.com/client/news/viw.asp?nNewsNumb=200807100065>
- [4] Carreira, Joao, and Andrew Zisserman. "Quo vadis, action recognition? a new model and the kinetics dataset." proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2017.
- [5] Feichtenhofer, Christoph, et al. "Slowfast networks for video recognition." Proceedings of the IEEE/CVF international conference on computer vision. 2019.
- [6] Radford, Alec, et al. "Learning transferable visual models from natural language supervision." International conference on machine learning. PmLR, 2021.
- [7] Liu, Haotian, et al. "Visual instruction tuning." Advances in neural information processing systems 36 (2023): 34892–34916.
- [8] Bai, Jinze, et al. "Qwen technical report." arXiv preprint arXiv:2309.16609 (2023).
- [9] Kyrkou, Christos, et al. "DroNet: Efficient convolutional neural network detector for real-time UAV applications." 2018 Design, Automation & Test in Europe Conference & Exhibition (DATE). IEEE, 2018.
- [10] Singh, Amarjot, Devendra Patil, and S. N. Omkar. "Eye in the sky: Real-time drone surveillance system (dss) for violent individuals identification using scatternet hybrid deep learning network." Proceedings of the IEEE conference on computer vision and pattern recognition workshops. 2018.
- [11] Bertasius, Gedas, Heng Wang, and Lorenzo Torresani. "Is space-time attention all you need for video understanding?." Icml. Vol. 2. No. 3. 2021.
- [12] Liu, Ze, et al. "Video swin transformer." Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022.
- [13] Bai, Shuai, et al. "Qwen2.5-vl technical report." arXiv, preprint arXiv:2502.13923 (2025).
- [14] Qwen Team, "Qwen2.5-VL-3B-Instruct," Hugging Face, 2024. Available: <https://huggingface.co/Qwen/Qwen2.5-VL-3B-Instruct>
- [15] AI Hub, "이상행동 CCTV 영상 데이터셋," 한국지능정보사회진흥원(NIA), 2021. [Online]. Available: <https://aihub.or.kr/>