

A Secure Federated LLM for Clinical Decision Support in Drug Prescription

YuNa Kim¹, SeongJin Lee¹, Changheun Oh² and Eun-Sung Jung^{1,*}

¹ High-Performance Data Processing and Analysis Lab, Department of Software Convergence, Hongik University, Sejong 30016, Korea; rladbsk2805@g.hongik.ac.kr, leesj7485@g.hongik.ac.kr; ejung@hongik.ac.kr

² Department of Software Convergence, Hongik University, Sejong 30016, Korea; choh@hongik.ac.kr

* Correspondence: ejung@hongik.ac.kr

Abstract

본 논문은 환자의 진단 정보가 주어졌을 때 적절한 처방 약물 리스트를 추천하는 대규모 언어 모델(LLM) 기반 시스템을 개발하는 것을 목표로 한다. 기존 단일 병원 데이터를 활용한 학습 방식은 약물 추천의 다양성과 성능 향상에 한계를 가지는 문제가 있으며, 이를 해결하기 위해 여러 병원의 데이터를 활용할 경우에도 환자의 민감한 의료 개인정보 보호 문제가 발생한다. 본 연구에서는 연합학습을 도입하여 데이터를 직접 공유하지 않고도 인공지능 LLM 이 각 병원 정보를 학습할 수 있도록 설계하였다. 또한 차등 프라이버시 기법을 적용하여 개인정보 노출 가능성을 최소화하고, FFA-LoRA(Federated Freeze A LoRA) 와 FlashAttention 을 결합하여 LLM 학습을 위한 연산 및 메모리 효율성을 최적화하였다. 실험 결과, 단일 학습 대비 연합학습 모델이 분산된 데이터 환경에서도 성능 저하 없이 안정적으로 수렴하였으며, 일부 조건에서는 단일 모델보다 더 나은 성능을 기록하였다. 특히, 병원 환자 데이터가 동일한 분포를 가지지 않는 non-IID 환경에서도 병원 간 정확도 격차가 일정하게 유지되어 학습의 안정성이 검증되었다. 본 연구는 환자 개인정보 보호와 학습 성능 향상을 동시에 달성할 수 있는 효과적인 접근법임을 보여주었으며, 향후 의료진 부족 문제 등의 문제 해결에 활용될 수 있다.

This paper aims to develop a Large Language Model (LLM)-based system that recommends an appropriate list of prescription medications given patient diagnostic information. Training on single-hospital data limits the diversity of prescription recommendations and restricts performance improvements, while using data from multiple hospitals raises concerns about protecting sensitive medical information. We introduce federated learning to enable an LLM to learn from multiple hospitals without sharing raw data. In addition, we apply differential privacy to reduce the risk of inferring sensitive information from model updates. To improve computational and memory efficiency during LLM fine-tuning, we combine Federated Freeze-A LoRA (FFA-LoRA) with FlashAttention. Experimental results show that, compared to single training, the federated model converges stably in distributed settings without performance degradation, and achieves improved performance under some conditions. In particular, even in a non-IID setting where hospitals have different patient distributions, the accuracy gap between hospitals remains consistent, supporting the stability of training. These results indicate that federated LLM training can support both privacy protection and competitive performance in clinical decision support.

Keywords: LLM, Llama, Federated Learning, LoRA, LoRA-FA, FlashAttention, Medical Data

1. Introduction

의료진 부족 문제가 지속적으로 보고되고 있다. 또한, 향후 보건 인력 부족 규모가 줄어들 것이라는 긍정적인 전망에도 불구하고, 의료진 부족은 여전히 전 세계적으로 심각한 문제로 남아있다 [2]. 한국에서는 간호사의 약 90%가 의사 부족의 영향을 체감하며, 의료적 책임이 자신에게 전가되었다고 답하는 등 [1] 이로 인해 응급 상황 환자에게 신속한 진료와 치료를 제공하는 데 어려움이 발생하고 있다. 예를 들어, 한국의 일부 지역에서는 젊은 의사들의 파업과 의료 인력 분배 문제로 응급실 운영에 차질이 발생했다는 보도가 있다. 또한, 의료 취약 지역에서는 공공의료 인력 부족이 장기간 지속되어 필수 의료 서비스 제공에 영향을 미치고 있다는 보고도 있다. 특히, 코로나 19 팬데믹 기간 동안에는 의료진의 과중한 업무 부담과 의료 시스템의 취약성이 더욱 부각되면서, 환자 안전과 신속한 치료 제공의 필요성이 대두되었다. 이러한 일들은 의료 자원의 효율적 분배와 병원 간 협력의 중요성을 다시 한번 일깨워 주고 있다. *Medical staff shortages have been continuously reported. Despite optimistic projections that the scale of health workforce shortages may decrease in the future, shortages remain a serious global issue [2]. In South Korea, about 90% of nurses report feeling the impact of physician shortages and indicate that medical responsibilities are being shifted to them [1]. As a result, it can become difficult to provide timely diagnosis and treatment in emergency situations. For example, some reports describe disruptions in emergency room operations due to strikes by junior physicians and issues in the distribution of medical personnel. In medically underserved areas, shortages of public healthcare staff can persist for long periods, affecting access to essential services. During the COVID-19 pandemic, the heavy burden on healthcare workers and the fragility of healthcare systems became more visible, further emphasizing the need for patient safety and timely treatment. These situations highlight the importance of efficient allocation of medical resources and collaboration across hospitals.*

위와 같은 문제 상황에서 의료진의 부담을 경감할 수 있는 자동화된 의료 진단 시스템의 필요성을 느껴 AI 를 통해 의료진 업무 부담을 덜어줌으로써 진단 수요 증가, 인력 부족, 그리고 주관적 해석 의존을 통해 해결하고자 하는 연구가 진행되었다. Jeong et. al[3]은 환자 진단에 알맞은 처방약물 리스트를 예측하여 의료진의 부담을 줄여주는 인공지능 시스템을 설계하였다. 추가적으로, McMahan et. al[4]는 여러 병원 간의 협력을 통해 대규모 학습데이터를 구축하는 과정에서 발생할 수 있는 환자의 의료 개인정보에 대한 프라이버시 보호 문제를 해결하기 위해 개인정보 데이터를 직접 공유하지 않고 가중치를 공유하는 연합학습방법을 제안하였다. *In response to these challenges, studies have explored automated medical decision-support systems that can reduce clinicians' workload by using AI, addressing increasing demand, limited staffing, and reliance on subjective interpretation. Jeong et al. [3] designed an AI system that predicts a prescription medication list suitable for patient diagnoses to reduce clinicians' burden. In addition, McMahan et al. [4] proposed federated learning, which shares model weights rather than directly sharing sensitive data, to address privacy risks that may arise when building large training datasets across multiple hospitals.*

본 논문의 최종 목표는 개인 의료정보 데이터를 다른 기관으로 공유하지 못하는 한계를 연합학습을 통해 극복하고, 의료진의 부담 및 약물 처방의 신뢰도를 높이기 위해 의사의 진단에 대한 자동화된 약물 처방 시스템을 구축하는 것이다. 효율적인 연합학습 방법을 제안하여 처방 약물 예측 모델의 성능을 향상시키고자 한다. 이를 위해 다음과 같은 주요 기법을 활용한다. 첫째, 효율적인 모델 미세조정(PEFT, Parameter-Efficient Fine-Tuning) 기법을 도입하여 통신 비용을 크게 절감하고 제한된 데이터 환경에서도 높은 성능을 유지할 수 있도록 한다. 둘째, 연합학습 과정에서 노이즈를 적용하여 환자의 의료 정보를 역추적할 가능성을 차단하고, 모델 학습 과정에서 개인정보 보호 수준을 향상시킨다. *The ultimate objective of this paper is to overcome the limitation that personal medical data cannot be shared across institutions, by using federated learning, and to build an automated drug prescription system that can reduce clinicians' burden and improve the reliability of prescriptions. We aim to improve the performance of a prescription*

medication prediction model by proposing an efficient federated learning approach with the following key techniques. First, we introduce parameter-efficient fine-tuning (PEFT) to reduce communication costs and to maintain performance under limited-data and resource-constrained environments. Second, we apply noise in the federated learning process to reduce the possibility of reverse inference of sensitive patient information from model updates, thereby strengthening privacy protection.

The main contributions of this study are as follows:

본 연구의 기존 연구 대비 특징 및 기여는 다음과 같다.

1. 대규모 언어모델(LLM)을 기반으로 한 약물 추천 시스템을 제안하였다. 기존 연구들이 주로 약물 반응, 내성, 상호작용 등의 개별 예측에 초점을 맞춘 데 비해, 본 연구는 환자의 진단 정보를 입력으로 받아 임상적으로 적절한 처방 약물 리스트 전체를 직접 예측하는 새로운 접근 방식을 취한다. LLM 을 활용함으로써 복잡한 진단 정보 간의 의미적 관계를 언어적 맥락 속에서 이해하고, 환자의 상태에 따라 타당한 약물 조합을 제안할 수 있다. 이를 통해 기존의 단순한 예측 모델보다 풍부한 임상 문맥을 반영하며, 의료진의 의사결정 과정에서 지능적으로 지원 할 수 있다.
2. LLM 과 LoRA-FA(Low-Rank Adaptation with Frozen-A) [5]를 결합한 연합학습 구조를 설계하였다. 기존의 연합학습 연구들은 대부분 LLM 을 적용하지 않았으나, 본 연구에서는 LLM 기반 모델에 파라미터 효율적 미세조정 기법인 LoRA-FA[5]를 도입하여 연산 비용을 최소화하고 효율적인 미세조정을 가능하게 하였다. 이를 통해 LLM 의 성능을 유지하면서도 자원 제약 환경에서도 효과적으로 학습할 수 있는 연합학습 구조를 구현하였다.
3. 실제 의료데이터(MIMIC-IV)를 활용한 Non-IID 환경 실험을 수행하였다. 특히, 환자의 연령대를 기준으로 명시적인 Non-IID 구성을 적용하여 실제 임상 환경을 반영하였다. 이를 통해 Client Drift 를 완화하고 연합학습의 수렴 안정성과 Non-IID 에 대한 견고성을 높였다.

본 논문은 다음과 같은 구조로 되어 있다. 2 장은 관련 연구에 대한 설명을 한다. 3 장에서는 환자 데이터 보호 및 연합 데이터 학습을 위한 LLM 설계 및 학습 방법을 기술한다. 4 장에서는 실험결과를 제시하고 이에 대해 논의한다. 마지막으로 5 장에서 결론짓는다.

1. LLM-based prescription recommendation. We propose a drug recommendation system based on a large language model (LLM). While many prior studies focus on individual predictions such as drug response, resistance, or interactions, our system aims to recommend an appropriate prescription medication list from a patient's current diagnostic information and context. By leveraging an LLM, the approach can better reflect rich clinical context and support clinicians' decision-making in a more flexible manner.

2. Federated architecture combining an LLM and LoRA-FA. We design a federated learning architecture that combines an LLM with LoRA-FA (Low-Rank Adaptation with Frozen-A) [5]. While many prior federated learning studies did not apply LLMs, we introduce LoRA-FA as a parameter-efficient fine-tuning approach to minimize computational cost and enable efficient fine-tuning. This supports effective learning under resource constraints while maintaining the LLM's capabilities.

3. Explicit non-IID experiments using real medical data. We conduct non-IID experiments using real medical data (MIMIC-IV). In particular, we construct an explicit non-IID setting based on patient age groups to reflect realistic clinical heterogeneity. This design helps analyze stability of convergence and robustness to client drift under non-IID conditions.

The remainder of this paper is organized as follows. Section 2 reviews related work. Section 3 describes the proposed LLM design and learning methodology for patient data protection and

federated training. Section 4 presents experimental results and discussion. Finally, the paper concludes in Section 5.

2. Related Work

본 절에서는 기존 연구를 설명한다. This section reviews previous studies.

2.1. AI Systems Supporting Medical Professionals

환자의 의료 정보 데이터는 의학연구에 있어서 매우 가치 있고 미래를 위한 혁신적인 잠재력을 지니고 있지만, 민감한 개인 정보가 포함되어 있어 프라이버시 침해의 위험이 존재한다. 기존 의료 시스템의 익명화 방법이나 개별 약물 반응 예측, 항생제 내성 예측, 약물 상호작용 예측 등의 기술은 환자 개별 특성을 반영하고 있으며, 특정 약물에 대한 반응이나 내성, 상호작용을 예측하는 데에 초점을 맞추고 있다. 한국에서는 GIST 연구팀의 PANCDR 모델은 환자의 유전자 발현 정보와 약물 그래프 정보를 활용하여 암 환자의 약물 반응을 예측하였고 [6], ImpriMed 기업의 정밀의료 AI 모델은 암 환자에 대해 최적의 항암 약물을 사전에 예측하였다 [7]. 또한, 아주대 의료원 연구팀은 감염질환 환자의 기저 특성, 진단 기록, 약물 처방 기록을 바탕으로 항생제 내성을 예측하였다 [8]. 국외에서도, Mukherjee et. al [9]은 과거 진단 및 검사 결과를 기반으로 진료시 발생 가능성이 높은 진단을 예측 모델을 제안하며, Choi et. al [10]은 환자 EHR(Electronic Health Record) 이력을 사용해 향후 진단 및 약물 처방을 예측하는 RNN 기반 모델이 존재한다. Medical data are highly valuable for research and have strong potential for future innovation; however, they contain sensitive personal information, creating privacy risks. Many existing studies focus on specific prediction tasks such as drug response, antibiotic resistance, or drug–drug interactions. In South Korea, the PANCDR model developed at GIST predicted cancer drug responses using gene expression data and drug graph information [6]. Precision-medicine AI models (e.g., ImpriMed) predicted optimal anticancer drugs for individual cancer patients [7]. Research at Ajou University Medical Center predicted antibiotic resistance using patient characteristics, diagnostic records, and prescription logs [8]. Internationally, Mukherjee et al. proposed a model that predicts likely diagnoses from past diagnoses and test results [9], and Choi et al. proposed an RNN-based model that predicts future diagnoses and medication prescriptions from EHR histories [10].

그러나 현재까지는 이러한 연구들이 약물의 반응, 내성 등에 초점을 맞추고 있으며, 환자의 과거 진단들을 기반으로 향후의 진단을 예측 할 뿐, 환자의 현재 진단 정보를 바탕으로 그에 알맞은 처방 약물 목록을 예측하는 시스템 개발 연구는 찾아보기 어렵다. 여러 의료기관에서 집계된 처방 데이터의 통계적 분석을 통한 임상 의사결정 지원(CDSS) 시스템은 존재하지만, 이는 주로 환자 개인의 처방 패턴 분석에 집중되어 있으며 [11], 진단 정보와 직접 연계하여 약물 리스트를 예측하는 방식과는 거리가 멀다.

본 연구는 이전 연구들과 다르게 현재 환자의 상태와 개인정보, 진단을 기반으로 적절한 약물을 예측하는 접근방식을 사용하고 있으며, 의료진의 부담을 줄이고 보다 신뢰할 수 있는 약물 처방 예측 시스템을 구축한다. However, most prior studies focus on drug response or resistance, or on predicting future diagnoses from historical records, rather than recommending an appropriate list of prescription medications based on a patient's current diagnostic information. Although clinical decision support systems (CDSS) exist that analyze prescription data across institutions, they are often centered on statistical prescription-pattern analysis and may not tightly couple diagnosis information to medication-list generation [11]. In contrast, this study focuses on recommending medications that are appropriate to a patient's current diagnostic information while addressing privacy constraints.

2.2. Model Training on Environments with Limited Computation/Communication Resources

기존 대규모 언어 모델(LLM) 을 활용한 연합학습 기반 미세 조정 (Fine-Tuning) 방식에서는 모델의 모든 가중치를 갱신하는 방식을 사용했다. 그러나 이러한 접근 방식은 높은 Computing 자원 요구량과 막대한 통신 비용을 초래하여 현실적으로 구현하기에는 어려움이 있다 [12]. 이를 해결하기 위해, 최근 한 연구 [12]에서는 FFA-LoRA(Federated Freeze A LoRA) 기법을 도입하여, 연합학습 환경에서 더욱 효율적인 미세 조정을 가능하게 하였다. 본 논문에서도 LLM 기반 연합학습 방식에서 FFA-LoRA 를 적용하였으며, 긍정적인 효과를 확인하였다. In federated fine-tuning of LLMs, updating all model weights is computationally expensive and incurs large communication costs, which makes deployment challenging [12]. To address this, a recent study introduced FFA-LoRA (Federated Freeze-A LoRA) to enable more efficient fine-tuning in federated environments [12]. In this paper, we apply FFA-LoRA in an LLM-based federated learning setting and observe positive effects in terms of practical fine-tuning efficiency and stability.

LoRA 계열 기법은 대규모 언어 모델을 보다 효율적으로 미세 조정하기 위한 대표적인 PEFT(Parameter-Efficient Fine-Tuning) 방법으로, 기본 LoRA 를 시작으로 다양한 변형이 제안되어 왔다. LoRA 는 저차원 행렬을 기존 모델에 삽입하여 전체 파라미터 수를 줄이고, 학습 효율을 높이는 구조를 갖는다 [13]. QLoRA 는 여기에 4-bit NormalFloat(NF4) 양자화를 적용함으로써, 메모리 사용량을 크게 절감하였다 [14]. DoRA(Weight-Decomposed Low Rank Adaptation)는 가중치를 크기(magnitude)와 방향(direction)으로 분해하여, 방향 성분에 LoRA 방식을 이다 [15]. LoRA-FA 는 LoRA 구조에서 A 행렬을 동결하고 B 행렬만을 학습하는 방식으로, 학습 파라미터 수를 추가로 줄이면서도 성능 저하를 최소화한 방식이다 [5]. LoRA-type methods are representative PEFT approaches for efficient fine-tuning of large language models. LoRA [13] reduces trainable parameters by freezing the original weights and learning low-rank matrices injected into selected layers. QLoRA further reduces GPU memory usage by applying 4-bit quantization (NF4) [14]. DoRA decomposes weights into magnitude and direction and applies LoRA to the direction component [15]. LoRA-FA [5] extends LoRA by freezing matrix A and training only matrix B , reducing trainable parameters further while limiting performance loss.

이 중 본 연구에서는 연합학습 환경의 특수성을 고려하여 LoRA-FA[5]를 채택하였다. 기존 LoRA [13]는 두 저차원 행렬(A , B)을 모두 학습 대상으로 하므로, 연합학습 [4]과 같이 클라이언트에서 업데이트된 파라미터를 FedAvg 방식으로 집계할 경우 수학적 불일치가 발생하여 수렴 안정성과 성능에 악영향을 미칠 수 있다. LoRA-FA [5]는 이러한 문제를 해결하기 위해, A 행렬을 고정하고 B 행렬만을 학습하도록 설계된 방식으로 학습하여 수학적 불일치를 제거한다. In this paper, we adopt LoRA-FA [5] particularly because of properties that matter in federated learning. In standard LoRA [13], both low-rank matrices (A and B) are trainable. When federated aggregation (e.g., FedAvg) averages client updates, this can introduce a mathematical mismatch in the aggregated low-rank factors, potentially harming convergence stability and performance. LoRA-FA reduces this issue by freezing A and training only B , removing a key source of aggregation mismatch.

본 논문에서는 LoRA-FA [5]를 단독으로 언급하는 경우를 제외하고, 연합학습에 적용된 LoRA-FA 의 경우에는 FFA-LoRA(Federated Freeze A LoRA) [12]라 칭한다. FFA-LoRA [12]는 연합학습 집계 시 발생하는 연산 오차를 방지하고 안정적인 수렴을 가능하게 한다. 나아가, 기존 LoRA 만으로도 모델의 학습 가능한 파라미터 수를 약 1,000 배 이상 줄이는데 효과적이지만, LoRA-FA 는 이를 더욱 개선하여 LoRA 대비 약 절반 수준으로 파라미터 수를 추가적으로 감소시킬 수 있다. 이로써 연합학습 과정에서의 통신 비용을 획기적으로 절감할 수 있다. In this paper, except when we refer to LoRA-FA [5] in isolation, we refer to LoRA-FA applied to federated learning as FFA-LoRA (Federated Freeze-A LoRA) [12]. FFA-LoRA [12] helps prevent aggregation errors and supports stable convergence. Moreover, while LoRA already reduces trainable parameters by roughly three orders of magnitude, LoRA-FA can further reduce trainable parameters to about half of LoRA, which can substantially reduce communication costs in federated learning.

더불어, FFA-LoRA 뿐만 아니라 FlashAttention-2 기법을 도입하여 메모리 사용량을 최적화하고 계산 효율성을 향상시켰다. FlashAttention-2 는 대규모 언어 모델 학습 환경에서 속도를 개선하고 GPU 메모리 부담을 줄이는 데 기여하여, 전반적인 학습 성능 향상에 더욱 효과적인 역할을 한다 [16].

결과적으로, FFA-LoRA [12]를 적용한 연합학습 방식은 기존의 모든 가중치를 업데이트하는 방식보다 현저히 적은 자원과 비용으로 효과적인 미세 조정을 가능하게 했으며, 통신 비용과 메모리 사용량을 동시에 최적화하는 접근 방식을 제시한다. 더불어 FlashAttention-2 [16]도 함께 사용하여 기존 연구를 보다 강화하는 방안을 제안하고, 향후 더욱 경량화 된 연합학습 기법으로 확장될 가능성을 시사한다.

In addition, we introduce FlashAttention-2 to optimize memory usage and improve computational efficiency. FlashAttention-2 improves training speed and reduces GPU memory burden when training large language models [16]. Combining FFA-LoRA [12] and FlashAttention-2 [16] provides an approach that optimizes communication cost and memory usage together, and suggests a practical path toward lightweight federated fine-tuning of LLMs.

2.3. Preventing the Reverse Tracking of Personal Information

연합학습은 데이터를 공유하지 않기 때문에 개인정보 보호 측면에서는 유리하지만, 클라이언트와 서버 간에 전달되는 Gradient 값을 통해 민감한 정보가 유출될 가능성이 있다는 연구 결과들이 보고되고 있다 [17]. 실제로 여러 논문에서는 연합학습 알고리즘만으로는 프라이버시 보호를 완전히 달성 할 수 없음을 제시하고 있다. 예를 들어, 한국전자통신연구원에서 발표한 “연합학습 기술 동향 및 산업적 시사점” 연구 보고서에 따르면, 공격자는 단말에서 서버로 전송되는 Gradient 값을 분석하여 특정 속성을 가진 샘플이 어느 배치에 포함되어 있는지 확인하거나, GAN(Generative Adversarial Networks)을 이용해 학습 데이터와 유사한 데이터를 생성하고 심지어 원래의 학습 데이터를 복원할 수도 있다는 연구 결과가 있다 [18]. 이에 대한 해결 방법으로 연합학습에 차등 프라이버시 기법을 도입하여 개인정보의 역추적을 불가능하게 함으로써 개인 정보 보호를 강화할 수 있다 [19]. 차등 프라이버시는 민감한 데이터가 포함된 데이터셋에 대해 수학적으로 강력한 프라이버시 보장을 제공하는 방법으로, 두 데이터셋이 단 한 개의 데이터 포인트만 다르더라도 분석 결과의 확률 분포가 크게 달라지지 않도록 노이즈를 추가하는 것이 그 핵심 아이디어이다 [20]. 이와 같이 노이즈를 추가하면 공격자가 모델 업데이트로부터 특정 개인의 데이터가 포함되어 있는지를 추론하기가 어렵게 된다.

Federated learning is advantageous for privacy because raw data are not shared. However, studies report that sensitive information can still leak through gradients exchanged between clients and the server [17]. For example, an ETRI report (“Federated Learning Technology Trends and Industrial Implications”) notes that an attacker may analyze gradients transmitted from devices to the server to infer batch membership, generate data similar to training data (e.g., using GANs), or even reconstruct original training samples [18]. As a mitigation, differential privacy can be integrated into federated learning by adding noise to reduce the feasibility of reverse inference, strengthening privacy protection [19]. Differential privacy provides a formal privacy guarantee by adding calibrated noise so that the result distribution does not change substantially even if a dataset differs by a single data point [20]. With noise, it becomes more difficult for an attacker to infer whether a specific individual’s data contributed to a model update.

기존의 차등 프라이버시 기법은 주로 의료 영상이나 일반 이미지 데이터를 처리하는 CNN(Convolutional Neural Network), MLP(Multi-Layer Perceptron) 등 소규모 모델에 적용되어 왔다. [19]에서는 연합학습 환경에서 차등 프라이버시를 도입했지만, 이는 LLM 이 아닌 상대적으로 규모가 작은 신경망 기반 예측 또는 분류 모델에 한정되어 있다. [21]에서는 LLM 과 연합학습의 결합을 제안하여 서버와 클라이언트 간 보안 통신 및 모델 분할을 통해 데이터 유출 위험을 경감하려 하였다. 하지만 해당 연구는 노이즈 추가를 통한 차등 프라이버시 보호 적용 관련해서는

구체적으로 다루고 있지 않다. 한편, 일부 연구 Google Research 의 “Protecting users with differentially private synthetic training data”에서는 연합학습 환경이 아닌 단일 시스템 학습 환경에서 LLM 의 미세조정(Fine-Tuning) 단계에 DP-SGD 와 같은 기법을 적용하여 차등 개인정보 보호를 구현한 사례가 보고되었지만, LLM 을 기반으로 하여 연합학습 환경에 노이즈 추가를 적용한 사례는 매우 제한적이다 [22]. Existing differential privacy approaches have mainly been applied to smaller models such as CNNs and MLPs [19]. While some work integrates differential privacy into federated learning, it often focuses on models smaller than LLMs (e.g., prediction/classification networks) [19]. Some studies propose combining LLMs and federated learning via secure communication and model partitioning, but do not explicitly focus on noise injection for differential privacy [21]. In centralized settings, Google Research reported cases of implementing differential privacy during LLM fine-tuning (e.g., DP-SGD) using differentially private synthetic training data, but examples that apply noise injection for LLMs in federated learning remain limited [22].

현재까지 LLM, 연합학습, 노이즈 추가(차등 프라이버시) 세 가지 요소를 모두 통합하여 다룬 연구는 명확하게 발표된 바 없으며, 이는 본 연구가 의료 데이터를 활용한 LLM 기반 연합학습에 노이즈 추가를 통한 차등 프라이버시를 구현하는 데 있어 매우 차별화된 연구임을 알 수 있다. 따라서 본 연구는 의료 데이터를 활용하여 LLM 기반 연합학습 과정에서 노이즈 추가를 통해 민감한 개인정보의 역추적 및 유출 위험을 획기적으로 줄이는 접근법을 제안한다. 이는 세 가지 핵심 요소를 통합한 최초의 시도로, 의료 데이터의 프라이버시 보호와 동시에 LLM 의 강력한 표현 능력을 활용할 수 있는 차별화된 기술적 기여로 평가될 것으로 기대한다. To our knowledge and based on the above context, there has not been a clearly published study that integrates all three elements—LLMs, federated learning, and explicit noise injection for differential privacy—into a single pipeline in the context of medical data. Therefore, this paper proposes an approach that applies noise injection in LLM-based federated learning to reduce the risk of reverse inference and privacy leakage in sensitive medical settings, while still leveraging the strong representational capacity of LLMs.

2.4. Enhancing Collaboration Between Hospitals

병원 간 협력을 통해 의료 지식 데이터를 공유하면 개별 병원의 데이터 편향성을 줄이고, 보다 포괄적인 정보를 제공하여 의료진의 처방 결정과 환자 치료에 큰 도움을 줄 수 있다. 여러 의료기관에 저장된 처방 데이터를 분석하면, 동일한 진단에 대해서 처방하고 있는 다른 약물 정보 데이터를 제공받을 수 있으며, 보다 통계적인 근거를 도출하여 객관적인 처방 결정을 지원할 수 있다. 데이터 공유는 의료 사고를 감소시키고 약물 상호작용 및 중복 처방을 예방하는 데 기여한다. 또한, 불필요한 처방을 줄여 의료비 절감 효과도 기대된다. 이처럼 여러 기관의 집계 정보는 단일 병원에서의 제한된 임상 경험을 넘어 다양한 환경과 진단의 처방 패턴을 반영하고, 의료진이 최적의 처방을 내릴 수 있도록 돕는다. Sharing medical knowledge across hospitals can reduce local data bias and provide more comprehensive information, helping clinicians with prescription decisions. Aggregated multi-institutional prescription data can support more evidence-based decisions, reduce medical accidents, prevent drug–drug interactions and duplicate prescriptions, and potentially reduce healthcare costs.

유사한 사례로는, 임상 의사결정 지원 시스템(CDSS)은 공공 및 민간 의료기관 간의 양방향 데이터 공유를 통해 의료 사고를 줄이고 환자 안전성을 크게 향상시켰다 [11]. 또한, 유럽의 국제 전자처방전 시스템이나 핀란드의 Kanta 서비스는 여러 기관에서 집계된 데이터를 기반으로 환자의 처방 기록과 약물 사용 내역을 실시간으로 공유함으로써, 약물 상호작용이나 중복 처방을 예방하고 알레르기 및 부작용 정보 등 환자 맞춤형 정보를 효과적으로 제공하였다 [24]. 더불어, 이러한 데이터 공유는 불필요한 약물 처방을 줄여 전체 의료비 절감에도 기여한다.

따라서 본 연구는 개별 병원의 데이터 편향성을 극복하고 마치 통합 데이터를 사용하는 것과 같은 효과를 주는 연합학습 구조를 제안함으로써, 의료진이 객관적인 통계 자료를 바탕으로 진단에 알맞은 약물을 선택할 수 있도록 지원하고자 한다. 이는 의료 사고를 줄이고 환자 안전성을 높이며, 맞춤형 치료와 의료비 절감에 효율적인 방법이 될 것으로 기대된다. A related example is clinical decision support systems (CDSS), which improved patient safety and reduced medical accidents through bidirectional data sharing between public and private institutions [11]. In addition, European international ePrescription systems and Finland's Kanta services share patients' prescription history and medication usage in real time across institutions, helping prevent interactions/duplications and support patient-specific information such as allergies and adverse events [24]. Therefore, this paper proposes a federated learning architecture that can reduce single-hospital bias while maintaining privacy, supporting a collaboration effect similar to using integrated data.

3. Enhanced Federated LLM for Drug Prescription

본 절에서는 본 연구에서 제안한 연합 LLM 설계 및 학습방법론을 설명한다. This section describes the proposed federated LLM design and learning methodology.

3.1. LoRA-FA (Low Rank Adaptation with Frozen A)

일반적으로 컴퓨팅 자원이 제한된 환경에서 LLM(대규모 언어 모델)의 모든 파라미터를 미세 조정하는 데 한계가 있다. 이에 효율적인 파라미터 미세조정 (PEFT, Parameter-Efficient Fine-Tuning)을 위해 제안된 기법 중 하나인 LoRA 를 적용하면, 계산 비용을 크게 절감하면서도 모델의 효율적인 미세 조정이 가능하다. LoRA [13]는 기존 가중치는 동결한 상태에서 일부 가중치 Layer 에 두 개의 저차원 행렬 곱을 추가하고 이 두 저차원 행렬을 이용해 학습함으로써 학습 가능한 파라미터 수를 대폭 줄일 수 있다. In general, fine-tuning all parameters of an LLM is difficult in resource-constrained environments. LoRA is a PEFT method that enables efficient fine-tuning while reducing computation cost. LoRA [13] freezes the original weights and adds low-rank matrices to selected layers, training only those low-rank matrices and thereby significantly reducing the number of trainable parameters.




Figure 1. Architecture overview of LoRA

본 연구는 Computing 자원이 제한된 환경에서도 LLM 모델의 학습이 가능하도록 하기 위해 LoRA 를 채택하였으나, 한 가지 문제점이 존재한다. Sun et. al [12]의 연구에 따르면, 연합학습 환경에서 LoRA 를 적용해 미세조정을 진행할 경우, 중앙 서버가 각 클라이언트의 업데이트를 집계하는 과정에서 오차가 발생하는 문제점이 발생한다고 주장하였다. 예를 들어, 두 클라이언트들로 구성된 연합학습 작업을 고려할 때, 각 클라이언트가 로컬에서 LoRA 파라미터를 업데이트한 후 중앙 서버가 FedAvg 알고리즘 [4]을 통해 이를 합산하는 과정을 다음 수식으로 표현할 수

있다. In this study, LoRA supports LLM fine-tuning in limited-resource environments, but a key issue arises in federated learning. According to Sun et al. [12], when LoRA fine-tuning is performed in federated learning, aggregation on the server can introduce an error due to how low-rank factors from different clients combine under FedAvg. For a simple two-client setting, the FedAvg aggregation process is described as:

$$W^+ = \frac{1}{2}(W_1 + W_2) = W_0 + \frac{1}{2}(\Delta W_1 + \Delta W_2) \quad \cdots (1)$$

$$W^+ = \frac{1}{2}(W_1 + W_2) = W_0 + \frac{1}{2}(\Delta W_1 + \Delta W_2) \quad \cdots (1)$$

여기서 W_1, W_2 는 각 클라이언트들의 가중치들을 나타내며, W_0 은 합산값을 업데이트 하기전에 있던 중앙 서버 모델의 파라미터이다. 중앙 서버에서 안전한 합산을 보장하는 암묵적인 가정은 다음과 같다. In (1), W_1 and W_2 denote the model weights of each client, and W_0 denotes the parameters of the central server model before updating the aggregated value, where secure aggregation at the central server implicitly assumes the following.

$$\Delta W_{global} \approx \frac{1}{2}(\Delta W_1 + \Delta W_2) \quad \cdots (2)$$

$$\Delta W_{global} \approx \frac{1}{2}(\Delta W_1 + \Delta W_2) \quad \cdots (2)$$

하지만 그림 1 에 나타난 바와 같이 각 클라이언트가 보유한 두 저차원 행렬 A 와 B 를 적용한 수식(수식 (3))을 이상적인 수식(수식 (4))과 비교해보면, 두 값이 일치하지 않는다는 점을 확인할 수 있다. (3) 수식은 Parameters after aggregation with LoRA + FedAvg 에 해당하는 수식이며, (4) 수식은 우리가 기대하는 Ideal parameters following model-averaging 수식이다. However, as shown in Figure 1, when we compare the formulation that applies the two low-rank matrices A and B held by each client (Eq. (3)) with the ideal formulation (Eq. (4)), we can see that the two are not identical. Eq. (3) corresponds to the parameters after aggregation with LoRA + FedAvg, whereas Eq. (4) represents the ideal parameters following model-averaging.

$$\tilde{W}^+ = W_0 + \frac{1}{2}(B_1 + B_2) \times \frac{1}{2}(A_1 + A_2) \quad \cdots (3)$$

$$\neq W_0 + \frac{1}{2}(B_1 A_1 + B_2 A_2) = W^+ \quad \cdots (4)$$

$$\tilde{W}^+ = W_0 + \frac{1}{2}(B_1 + B_2) \times \frac{1}{2}(A_1 + A_2) \quad \cdots (3)$$

$$\neq W_0 + \frac{1}{2}(B_1 A_1 + B_2 A_2) = W^+ \quad \cdots (4)$$

중앙 서버에서 평균을 이용해 로컬 업데이트를 집계할 때 오차가 발생함을 확인할 수 있다. Sun et. al(2024) [12]의 연구에서는 그림 2 와 같이 두 저차원 행렬 중 A 행렬을 고정(동결)하고 B 행렬만 학습 가능한 파라미터로 유지하는 방식인 LoRA-

FA 제안하여 문제를 해결하였다. 해당 방식을 수식과 그림으로 나타내면 다음과 같다. This indicates that aggregating local updates via simple averaging at the central server can introduce an error in the aggregated update. To address this issue, Sun et al. (2024) [12] proposed LoRA-FA, which freezes the A matrix among the two low-rank matrices and keeps only the B matrix as trainable parameters, as illustrated in Figure 2. The method can be expressed using the following Eq. (5) and Figure 2.

$$W_0 + \frac{1}{2}(B_1 + B_2) \times A_0 = W_0 + \frac{1}{2}(B_1 A_0 + B_2 A_0) \quad \cdots (5)$$

$$W_0 + \frac{1}{2}(B_1 + B_2) \times A_0 = W_0 + \frac{1}{2}(B_1 A_0 + B_2 A_0) \quad \cdots (5)$$




Figure 2. Architecture overview of LoRA-FA

수식 (5)는 이상적인 집계 수식과 일치하기 때문에 오차 발생 없이 연산이 가능해졌다. 또한, FFA-LoRA [12]를 용하여 미세조정 한 모델과 기존 LoRA 만을 사용한 성능 비교 결과와 비슷하거나 오히려 더 높은 정확도를 보여주고 있다. Because Eq. (5) matches the ideal aggregation form, aggregation can be performed without the mismatch. In addition, empirical results reported in [12] indicate that models fine-tuned using FFA-LoRA can achieve accuracy comparable to or higher than standard LoRA in similar settings.

Table 1. Comparison of performance (accuracy) on various GLUE tasks (MNLI, SST-2, QQP, QNLI) when applying LoRA and FFA-LoRA.

Priv.Budget	Method	MNLI (matched)	MNLI (mismatched)	SST-2	QQP	QNLI
Non Private	LoRA	82.03 _{±10.7}	82.50 _{±10.9}	94.32 _{±2.1}	83.51 _{±3.3}	88.95 _{±6.7}
	FFA-LORA	85.05 _{±1.1}	85.62 _{±0}	94.32 _{±1.7}	84.35 _{±0.6}	90.35 _{±1.9}

3.2. FlashAttention

Transformer 모델에서 Self-Attention 연산은 기본적으로 입력 시퀀스의 모든 토큰 간의 관계를 계산하게 된다. 이를 위해 Query, Key, Value 행렬을 생성하고, 아래와 같이 Attention 가중치를 계산한다. In Transformer models, Self-Attention computes

relationships among all token pairs in an input sequence. Using Query ($\mathbf{Q}$), Key ($\mathbf{K}$), and Value ($\mathbf{V}$), Attention weights are computed as :

$$Attention(Q, K, V) = softmax\left(\frac{QK^T}{\sqrt{d_k}}\right)V \dots (6)$$

$$Attention(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = softmax\left(\frac{\mathbf{Q}\mathbf{K}^T}{\sqrt{d_k}}\right)\mathbf{V} \dots (6)$$

이 과정에서 입력 시퀀스 길이(N)에 대해 모든 토큰 쌍관계를 계산해야 하므로, N 증가할수록 계산량과 메모리 사용량이 $O(N^2)$ 으로 증가하는 문제가 발생하였다. 이는 시퀀스 길이가 두배가 되면서, 연산량과 메모리 사용량이 네 배로 증가하여, 학습 및 추론 속도 저하와 심각한 병목 현상을 초래한다. In this process, the model must compute interactions for all token pairs with respect to the input sequence length N , which leads to a computational and memory cost that grows as $O(N^2)$ as N increases. In particular, when the sequence length doubles, both the computation and memory requirements increase by a factor of four, which slows training and inference and can create a severe bottleneck.

이러한 문제를 해결하고자 Self-Attention 연산 메모리 사용량을 최적화하여, 메모리 병목을 줄이고 연산 속도를 향상 시키는 FlashAttention 기법을 도입한다. FlashAttention-1 [25]은 Self-Attention 연산을 블록 단위로 수행하고 전체 연산을 나눠 메모리 사용량을 최적화한다. 또한, GPU 의 글로벌 메모리 접근을 최소화하여 보다 빠른 공유 메모리(Shared Memory)를 적극 활용하여, 데이터 이동을 최소화하는 방식으로 동작한다. 그러나 FlashAttention-1 [24]은 메모리를 크게 절약하고 일부 속도를 향상시키지만, 여전히 최적화된 행렬 곱셈(GEMM) 연산 만큼 빠르지 않다는 한계가 존재한다. 이를 극복하기 위해서 FlashAttention-1 [24]을 기반으로 더 높은 병렬성과 연산 최적화를 적용한 FlashAttention-2 를 적용한다 [16]. To address this issue, we adopt FlashAttention, which optimizes the memory usage of self-attention to reduce memory bottlenecks and improve computational speed. FlashAttention-1 [25] performs the self-attention computation in block-wise fashion and partitions the overall computation to optimize memory usage. It also minimizes accesses to GPU global memory by actively leveraging faster shared memory, thereby reducing data movement. However, while FlashAttention-1 [24] significantly reduces memory consumption and provides some speedup, it still has the limitation that it is not as fast as highly optimized GEMM (general matrix multiplication) operations. To overcome this limitation, we apply FlashAttention-2, which builds on FlashAttention-1 [24] with higher parallelism and further computational optimizations [16].

FlashAttention-2 [16]는 FlashAttention-1 [24]의 기본 구조를 유지하면서도 연산량(FLOPs)을 줄이고 병렬성을 강화하는 최적화 기법을 추가하였다. 주요 개선점은 다음과 같다. FlashAttention-2 [16] retains the basic structure of FlashAttention-1 [24] while adding optimization techniques that reduce computational cost (FLOPs) and enhance parallelism. The main improvements are as follows.

1. Non-Matmul FLOPs 감소시킨다. 기존 Transformer 의 Self-Attention 연산에서는 행렬곱셈 외에도 Softmax, Normalization 등 추가적인 연산이 포함된다. 이 과정에서 GPU 글로벌 메모리를 반복적으로 접근해야 하는 경우가 존재하여 불필요한 연산이 발생한다. 이에 FlashAttention-2 은 Non-Matmul 연산을 최적화하여, 불필요한 FLOPs 를 줄이고 성능을 향상시켰다. 즉, 메모리 접근 횟수를 최소화하고 연산 경로를 간소화함으로써 처리 속도를 높인다. Reducing non-matmul FLOPs. In the self-attention computation of

standard Transformers, additional operations beyond matrix multiplications—such as Softmax and normalization—are included. In this process, repeated accesses to GPU global memory can occur, leading to unnecessary overhead. FlashAttention-2 optimizes these non-matmul operations to reduce redundant FLOPs and improve performance. In other words, it minimizes memory accesses and simplifies the computation path, thereby increasing throughput.

2. Attention 연산을 GPU 여러 스레드 블록에서 병렬화 한다. 기존 Transformer에서는 전체 Attention 연산을 단일 GPU 인 하나의 GPU 스레드 블록이 전체 Attention 연산을 수행했기 때문에 병목현상이 발생하였다. 이러한 문제를 해결하고자 FlashAttention-2에선 여러 개의 GPU 스레드 블록을 활용하여 연산을 분산함으로써, 병렬 처리 능력을 크게 강화한다. 이를 통해 한 블록에 의존하는 병목 현상을 해소하고, 전체적인 연산 처리량을 증대 시킨다. *Parallelizing attention computation across multiple GPU thread blocks. In standard Transformers, the entire attention computation may be executed within a single GPU thread block, which can create a bottleneck. FlashAttention-2 addresses this issue by distributing the computation across multiple GPU thread blocks, substantially strengthening parallel processing capability. This reduces reliance on a single block, alleviates bottlenecks, and increases overall computational throughput.*
3. 작업을 공유 메모리에를 활용하여 최적화한다. 기존 Transformer 의 Self-Attention 연산에서는 GPU 글로벌 메모리에서 데이터를 반복적으로 읽고 쓰는 과정이 많아, 메모리 대역폭 병목이 발생했다. FlashAttention-1 은 GPU 의 공유 메모리를 적극 활용하여, 중간 계산 결과를 저장하고 빠르게 접근 할 수 있도록 한다. FlashAttention-2 는 이러한 공유 메모리 활용 방식을 더욱 정교하게 최적화하여, 메모리 접근 지연을 줄이고, 연산 효율을 극대화하였다. *Optimizing workloads using shared memory. In standard Transformer self-attention, frequent reads and writes to GPU global memory often cause a memory-bandwidth bottleneck. FlashAttention-1 actively uses GPU shared memory to store intermediate results and enable fast access. FlashAttention-2 further refines and optimizes this shared-memory utilization strategy, reducing memory-access latency and maximizing computational efficiency.*

FlashAttention-2 [16]은 Transformer 모델을 획기적으로 향상시킬 수 있는 중요한 기술이며, 긴 시퀀스를 다루는 대형 언어 모델(LLM)에서 필수적인 요소로 활용되고 있다. 이에 본 연구에서도 FlashAttention-2 을 도입한다 *FlashAttention-2 [16] is widely used for improving Transformer efficiency in long-sequence settings, and we adopt FlashAttention-2 in this study.*

3.3. Backbone Model

예측 모델을 구축하기 위해 Backbone 모델로 Meta 의 Llama3.1-8B-Instruct 모델 [26]을 채택하였다. 해당 모델은 80 억 개의 비교적 작은 파라미터 수 대비 높은 성능을 제공하며, FlashAttention-2 [16]와의 호환을 지원하여 높은 유연성을 갖춘 구조를 지니고 있다. 또한 instruction 기반 미세 조정(instruction-tuned fine-tuning)에 최적화되어 있어 특정 하위 작업에 적합한 학습을 쉽게 수행할 수 있다. 사전 학습된 Llama3.1-8B-Instruct 의 가중치를 동결(Frozen)하여 학습 가능하지 않도록 설정하고, 미세 조정 방식으로 FFA-LoRA 를 도입하였다. 기존 LoRA 의 최적화 방식과 동일하게 W_q (쿼리) 및 W_v (값) 레이어에 어댑터를 적용하였다. 이러한 기존 LoRA 대신 FFA-LoRA [12]방식은 연합학습 환경에서 통신 비용을 절감하고 학습 가능한

파라미터 수를 기존 80 억 개에서 약 680 만 개로 대폭 감소시킬 수 있다. 추가적으로
FlashAttention-2 layer 를 적용함으로써 기존 Self-Attention 에 비해 연산량 감소로
속도 향상과 메모리 절감을 하였다. FFA-LoRA [12]를 적용한 후 데이터 타입에 따른
메모리 절감 효과를 분석한 결과, FP32(32-bit Floating point) 자료형 적용 시 약 32GB
메모리 절약 가능하고, FP16(16-bit Floating point) 자료형 적용 시 약 16GB 메모리
절약 가능하다. 이러한 최적화는 특히 연합학습 환경에서 클라이언트 측 장치의
메모리 사용량을 최소화하는 데 매우 큰 기여를 한다.

To build the prescription recommendation model, we adopt Meta’s Llama3.1-8B-Instruct as
the backbone model [26]. The model delivers strong performance despite its relatively small size
(8B parameters) and is compatible with FlashAttention-2 [16], enabling efficient training.
Moreover, as an instruction-tuned model, it is well-suited for instruction-based fine-tuning on
downstream tasks. We freeze the pre-trained Llama3.1-8B-Instruct weights and introduce FFA-
LoRA [12] as a parameter-efficient fine-tuning approach. Following the standard LoRA setup, we
apply adapters to the $\mathbf{W}_q$ (query) and $\mathbf{W}_v$ (value) layers. In federated learning, FFA-LoRA [12]
reduces communication cost and decreases the number of trainable parameters from 8 billion to
approximately 6.8 million. In addition, applying FlashAttention-2 layers reduces computational
cost and memory usage compared with standard self-attention. After applying FFA-LoRA [12], the
memory savings depend on the data type: using FP32 (32-bit floating point) can save approximately
32 GB of memory, while using FP16 (16-bit floating point) can save approximately 16 GB. These
optimizations can substantially reduce client-side memory usage in federated learning
environments.




Figure 3. Model Architecture

3.4. Federated Learning

3.4.1. Federated Learning

연합학습 (Federated Learning, FL)이란, 중앙 서버에 데이터를 직접 공유하지 않고, 개별 클라이언트에서 학습된 모델 가중치를 서버에 전송하여 집계하는 기법이다 [4]. 이를 통해 병원 간 협력을 통해 적절한 약물 처방의 다양성을 높이면서도, 환자의 개인 의료 정보를 직접 공유하지 않기 때문에 데이터 프라이버시 보호가 가능하다. Federated learning (FL) aggregates locally trained model weights at a central server without directly sharing raw data [4]. This allows hospitals to collaborate to increase the diversity of prescription recommendations while protecting sensitive patient information because data remain local.

연합학습 [4]은 데이터를 한 곳으로 모아 학습하는 방식과 비교했을 때 다음과 같은 장점을 갖는다. 첫째, 데이터가 로컬 환경에서만 유지되므로 환자의 민감한 개인 의료 정보가 서버로 직접 전송되지 않기 때문에 개인정보 보호를 강화할 수 있다. 둘째, 병원 간 협력을 통해 보다 다양한 처방 측면을 고려한 의료 시스템을

구축할 수 있으며, 데이터 편향성을 완화할 수 있다. 셋째, 네트워크 대역폭과 서버의 저장소 부담을 줄여 분산 환경에서도 효율적인 모델 학습을 가능하게 한다. Compared with centralized training, federated learning has the following advantages [4]. First, sensitive patient records remain local and are not transmitted to the server, strengthening privacy protection. Second, collaboration across hospitals helps consider more diverse prescription patterns and can mitigate local bias. Third, it can reduce network bandwidth and server storage burden because raw datasets are not transferred, enabling efficient training in distributed environments.

3.4.2. IID Environment & Non-IID Environment

연합학습은 데이터 프라이버시를 유지하기 위해 서버에서 클라이언트의 데이터를 통합하여 학습하는 것이 아닌 각 클라이언트 단에서 로컬 데이터를 사용해 모델을 학습하는 방식이다. 이때, 각 클라이언트의 데이터 분포가 동일할 경우는 IID(Independent Identically Distribution)환경, 그렇지 않을 경우 Non-IID (Non-Independent Identically Distribution)환경으로 구분된다 [26]. IID 환경이란, 각 데이터 샘플이 동일한 확률 분포에서 서로 독립적일 때를 의미한다. 간단하게 말하면 각 데이터 포인트는 다른 데이터 포인트와 독립적이지만, 동일한 확률 분포를 따른다. Non-IID 환경이란, 데이터가 서로 독립적이지 않거나 동일한 확률 분포를 따르지 않는 상황을 의미한다. 즉, 각 클라이언트가 서로 다른 label 분포를 가지거나, 데이터가 특정 클래스에 편중되어 불균형한 확률 분포를 나타낼 수 있음을 뜻한다. 이러한 특성은 연합 학습(Federated Learning)에서 모델의 일반화 성능과 수렴 속도에 영향을 미칠 수 있다. Federated learning trains models using local data at each client rather than using a single pooled dataset. If each client's data distribution is the same, the environment can be considered IID (independent and identically distributed). If not, the environment is non-IID [26]. In an IID environment, data points are independent while following the same probability distribution. In a non-IID environment, data may not be independent or may not follow the same distribution across clients. For example, clients may have different label distributions, or data may be skewed toward specific classes, causing imbalanced distributions. These characteristics can affect convergence speed and generalization in federated learning.

결론적으로, Non-IID 환경에서의 주요 원인은 다음과 같다. In summary, the main causes of Non-IID environments are as follows.

- 1). Label Skew : 특정 클라이언트의 데이터가 한정된 레이블만 포함하여 모델이 특정 클래스에 과적합된다. Label skew: a client has data concentrated in certain classes, causing local overfitting.
- 2). Feature Skew : 같은 레이블이라도 클라이언트마다 특징 분포가 달라 일반화가 어려워지고 성능이 불균형해진다. Feature skew: even with identical labels, feature distributions differ across clients, harming generalization.
- 3). Quantity Skew : 클라이언트마다 데이터 개수가 달라 데이터가 많은 클라이언트에 의해 모델이 편향될 위험이 증가한다. Quantity skew: different client dataset sizes bias the global model toward clients with more data.

앞선 세 가지의 원인으로 인해 통계적 이질성(Statistical Heterogeneity)가 발생하며, 다음과 같은 문제를 야기한다. 첫째, 각 클라이언트의 모델 업데이트 방향이 서로 다르게 흘러가게 되면서, 로컬 모델 간의 편차가 커지게 된다. 둘째, 글로벌 모델 업데이트 시 단순 평균으로 통합할 경우, 각 로컬 모델의 편차가 그대로 반영되어 전체 데이터의 대표성을 상실한다. 또한, 학습이 불안정해지거나 수렴 속도가 저하되는 문제가 발생한다. 결론적으로 글로벌 모델의 일관성이 깨지게 된다. 이처럼 로컬 업데이트 횟수가 증가하면서 글로벌 업데이트의 방향과 이상적인 업데이트 방향이 다르게 나타나는 현상을 Client Drift [27]라고 한다. These factors lead to statistical heterogeneity, which in turn causes several issues. First, as the directions of model

updates differ across clients, the discrepancy among local models increases. Second, if global model updates are obtained by simple averaging, these discrepancies are directly reflected, reducing representativeness of the aggregated model with respect to the overall data. In addition, training can become unstable and convergence may slow down, ultimately breaking the consistency of the global model. This phenomenon—where the global update direction deviates from the ideal update direction as the number of local updates increases—is referred to as client drift [27].

Client Drift 문제를 해결하기 위해 여러 방법이 제시되고 있는데, 실용적 측면의 경우 각 클라이언트가 일부 데이터를 중앙 서버에 제출해 공용 데이터셋을 구성할 수도 있으나, 이는 데이터 보안성 측면에서 부적절하다고 판단하였다. 최근 블록체인 연합 학회 CURG(Crypto United Research Group)에서는 데이터 증류(Dataset Distillation) 기법을 제안하여 이러한 문제를 해결하기도 하였다. A number of methods have been proposed to address the client-drift problem. From a practical perspective, clients may submit a portion of their data to the central server to construct a shared dataset; however, we consider this approach inappropriate from the standpoint of data security. Recently, the blockchain federated research community CURG (Crypto United Research Group) also proposed a dataset distillation technique to mitigate this issue.

본 연구에서는 Non-IID 문제와 더불어 커뮤니케이션 비용 문제를 함께 고려하기 위해 Google 에서 제안한 FedAvg(Federated Averaging) 알고리즘을 사용한다 [4]. 기존의 단순 평균 방법으로는 클라이언트 간 데이터 양의 불균형을 충분히 반영하지 않아 Client Drift 문제를 야기하지만, Google 이 제안한 FedAvg 의 경우 각 클라이언트의 로컬 업데이트를 각 클라이언트가 보유한 데이터 샘플 수에 비례하여 가중 평균하는 방식을 사용한다 [4]. In this study, to account for both the Non-IID issue and communication cost, we use FedAvg (Federated Averaging), an algorithm proposed by Google [4]. Simple averaging does not sufficiently reflect imbalance in data quantity across clients and can exacerbate client drift, whereas FedAvg aggregates local updates using a weighted average proportional to the number of data samples held by each client [4].

Algorithm 1 FederatedAveraging. The K clients are indexed by k ; B is the local minibatch size, E is the number of local epochs, and η is the learning rate.

Server executes:

```

Initialize  $w_0$ 
for each round  $t = 1, 2, \dots$  do
   $m \leftarrow \max(C \cdot K, 1)$ 
   $S_t \leftarrow$  (random set of  $m$  clients)
  for each client  $k \in S_t$  in parallel do
     $w_{t+1}^k \leftarrow \text{ClientUpdate}(k, w_t)$ 
   $m_t \leftarrow \sum_{k \in S_t} n_k$ 
   $w_{t+1} \leftarrow \sum_{k \in S_t} \frac{n_k}{m_t} w_{t+1}^k$  //Erratum4

```

ClientUpdate(k, w) : // Run on client k

```

 $\mathcal{B} \leftarrow$  (split  $\mathcal{P}_k$  into batches of size  $B$ )
for each local epoch  $i$  from 1 to  $E$  do
  for batch  $b \in \mathcal{B}$  do
     $w \leftarrow w - \eta \nabla \ell(w; b)$ 
return  $w$  to server

```

Figure 4 FedAvg Algorithm. The K clients are indexed by k ; B is the local minibatch size, E is the number of local epochs, and η is the learning rate.

이로써 클라이언트 간 편차를 보정하고 글로벌 모델의 대표성을 유지할 수 있다. 이러한 접근 방식은 McMahan et al [4]에 제시된 근거를 따른다. This allows us to correct discrepancies across clients and maintain the representativeness of the global model. This approach follows the rationale presented by McMahan et al. [4].

3.4.3. Differential Privacy

연합학습은 원본 데이터를 공유하지 않기 때문에 개인정보 보호 측면에서 유리하지만, 모델 업데이트 과정에서 여전히 몇 가지 보안 및 프라이버시 문제가 존재한다. 예시로 알수 없는 네트워크 공격자가 각 클라이언트의 모델 업데이트를 분석할 경우 원본 데이터 분포를 역추적(Remote Engineering)하는 것이 가능하다. 이는 민감한 정보가 포함된 의료 및 금융 데이터의 보호 측면에서 큰 위협이 될 수 있다. 이러한 문제를 해결하기 위해 차등 프라이버시(Differential Privacy, DP)기법이 연합학습에 도입된다. 차등 프라이버시는 민감한 데이터가 포함된 데이터셋에 특정 분포를 가진 노이즈를 추가하여 강력한 프라이버시 보장을 제공하는 방법이다 [28]. 즉, 공격자가 모델 업데이트 과정에서 특정 개인의 데이터가 포함되었는지를 추론할 수 없게 만든다. 먼저 모델 업데이트나 통계 분석 과정에서 민감한 데이터의 기여도를 감추기 위해, Laplace 분포나 Gaussian 분포와 같은 적절한 분포를 따르는 노이즈를 추가한다. 해당 노이즈는 개별 데이터 포인트가 모델에 미치는 영향을 희석시켜, 결과적으로 공격자가 특정 데이터 포인트의 존재 여부를 파악하기 어렵게 만든다 [29]. 또한, 차등 프라이버시는 ϵ (엡실론)과 δ (델타)라는 두 개의 매개변수를 통해 프라이버시 손실을 정량화한다. ϵ 값이 작아질수록 강력한 프라이버시 보장을 의미하지만, 동시에 정보 손실이 발생하여 모델 성능에 영향을 줄 수 있기 때문에 실제 시스템에서는 모델의 유용성과 프라이버시 보장 간의 트레이드오프를 고려해야 한다. δ 값은 차등프라이버시의 추가적인 프라이버시 보장을 위해 도입된 매개변수이다. ϵ 이 프라이버시 손실의 상한을 나타낸다면, δ 는 프라이버시 보장을 위반할 가능성을 나타내며 수치가 증가할수록 프라이버시 보장이 약해진다. 하지만 너무 작은 δ 값은 모델의 유용성에도 영향을 줄 수 있기 때문에 ϵ 와 적절한 균형이 필요하다 [29]. Although federated learning does not share raw data, privacy risks still exist because an attacker may analyze model updates and infer underlying data distributions (reverse engineering). This is especially threatening for sensitive domains such as healthcare and finance. To address this, differential privacy (DP) is integrated into federated learning. Differential privacy provides strong privacy protection by adding noise from a specified distribution to computations on sensitive datasets [28]. By adding Laplace or Gaussian noise, individual data points' influence is reduced, making it hard for an attacker to determine whether a specific record was included [29]. Differential privacy quantifies privacy loss using two parameters, ϵ (epsilon) and δ (delta). A smaller ϵ typically implies stronger privacy but can introduce greater information loss that affects model performance; in practice, the trade-off between utility and privacy must be considered. δ represents an additional privacy parameter corresponding to the probability of privacy guarantee failure.

연합학습의 프레임워크인 Flower 는 연합학습이 수행되고 있는 과정에서 언제 노이즈가 추가 되는지에 따라 다양한 차등 프라이버시를 제공한다 [30]. 첫번째 방법은 클라이언트들의 가중치가 서버에 전송되고, 이후 서버에서 집계된 가중치에 노이즈를 적용하여 차등 프라이버시를 보장하는 방식이다. 두번째 방법은 서버로 보내기 전 각 클라이언트 정보에서 노이즈를 추가하여 전송한다. 이는 서버로 전송되기 전에 미리 가중치에 노이즈를 추가하여 차등 프라이버시를 보장하는 방식이다. 본 연구에서는 첫번째 방법을 적용하여, 모델 업데이트로부터 민감한 개인 정보 역추적을 불가능하게 하였다. Flower, a federated learning framework, provides different differential privacy mechanisms depending on when noise is added in the federated process [30].

One approach adds noise on the server after aggregation of client updates (central DP). Another approach adds noise at each client before sending updates. In this study, we apply the first approach (server-side central DP) so that reverse inference from model updates is more difficult.

4. Results and Discussion

4.1. 평가 방식 Evaluation Method

LLM 의 성능 평가를 하기 위해서는 입력에 따른 출력의 변화와 그 결과의 정확성을 분석하는 것이 중요하다. 특히 프롬프트(prompt)와 컨텍스트(context)가 평가에서 중요한 구성 요소이며, 다양한 성능 지표를 활용하여 모델의 정확도를 측정하고 비교할 수 있다. 본 연구에서는 Human Evaluation 을 활용하여 보다 객관적이고 효율적인 평가를 진행한다. To evaluate LLM performance, it is important to analyze how outputs change with inputs and how accurate those outputs are. Prompts and context are key components, and multiple metrics can be used to measure accuracy and compare models. In this study, we use human evaluation to conduct a more objective and efficient assessment.

Human Evaluation 은 사람이 직접 평가 기준을 정하여 모델 출력을 분석하는 방식이다. 본 연구에서는 테스트 데이터셋의 진단에 따른 약물 리스트를 정답으로 가정하고 평가하였다. 평가 기준은 다음과 같다. Human evaluation means that people define evaluation criteria and analyze model outputs accordingly. We treat the medication list corresponding to each diagnosis in the test dataset as the ground truth. The evaluation criteria are:

- 1). 원하는 형식에 맞게 응답을 생성하였는가? Did the model generate a response in the desired format?
- 2). 출력된 약물 리스트가 정답의 리스트와 비교하여 얼마나 유사하게 판단하였는가? How similar is the predicted medication list to the ground truth list?

정답이라 가정하는 테스트 데이터셋에도 한 질문에 여러 약물이 처방되어 있으며, 추론 결과 역시 여러 약물이 처방되어 있다. 따라서 정확도를 계산하는 과정에서는 각 답변에서 출력된 약물 개수를 기준으로, 정답과 일치하는 약물 수의 확률을 구한 후 평균으로 계산하였다. In the test dataset treated as the ground truth, a single question is associated with multiple prescribed medications, and the model outputs multiple medications as well. Therefore, to compute accuracy, we calculate, for each sample, the fraction of predicted medications that match the ground-truth medication set, and then average this fraction across all samples.

$$Accuracy = \frac{1}{N} \sum_{i=1}^N \left(\frac{\text{정답과 일치하는 약물 개수}}{\text{전체 출력된 약물 개수}} \right)_i \dots (7)$$

$$Accuracy = \frac{1}{N} \sum_{i=1}^N \left(\frac{\text{Number of correctly matched medications}}{\text{Total Number of output medications}} \right)_i \dots (7)$$

4.2. 실험 환경 Experimental Environment

실험은 두 종류의 병원에 연합학습 네트워크를 적용한다 라는 상황을 가정하여 네트워크를 구축하였다. 따라서 병원의 시스템을 대체할 클라이언트 두개, 클라이언트 결과를 집계할 서버까지 총 3 개의 시스템이 필요하다. 서버의 경우

AMD Ryzen Threadripper PRO 5955WX 16-Cores CPU, RTX 4080 24GB GPU 두개를 사용하였고, 두 클라이언트 시스템은 모두 동일하게 AMD Ryzen Threadripper PRO 3955WX 16-Cores CPU, RTX 6000 Ada Generation 48GB 로 구성하였다. We construct a federated learning network under the assumption of two hospitals. The system therefore requires three components: two clients representing hospitals and one server that aggregates client updates. The server uses an AMD Ryzen Threadripper PRO 5955WX 16-Cores CPU and two RTX 4080 24GB GPUs. Each client system uses an AMD Ryzen Threadripper PRO 3955WX 16-Cores CPU and an RTX 6000 Ada Generation 48GB GPU.

4.3. Experimental Setup

4.3.1. Learning Method

서버와 클라이언트 모두 동일한 Llama3.1 8B Instruct 모델을 사용하고, 연합학습 네트워크 구현을 위해 Flower Framework [31]를 사용하였다. 실제 학습은 클라이언트의 로컬 모델에서 진행되며, 학습을 완료한 후 최종 가중치를 서버로 전송한다. 서버는 클라이언트로 부터 전달받은 모델 가중치에 노이즈를 추가한 후, 이를 집계하여 저장하는 역할을 수행한다. 따라서 서버는 클라이언트로 부터 전달받은 가중치들을 이용해 글로벌 모델을 업데이트하며, 이 과정을 한 라운드로 정의하고, 이를 총 n 라운드에 걸쳐 반복한다.

Both the server and the clients use the same Llama3.1-8B-Instruct model, and we implement the federated learning network using the Flower framework [31]. Training is performed on each client's local model, and after completing local training, the client sends its final weights to the server. The server adds noise to the model weights received from the clients and then aggregates and stores them. Accordingly, the server updates the global model using the client-provided weights. We define this procedure as one round and repeat it for a total of n rounds.

4.3.2. Server

서버의 노이즈 추가는 Flower 연합 학습 Framework 에서 제공하는 Central Differential Privacy 알고리즘을 적용한다. 이는 클라이언트가 가중치를 전송하는 과정에서 노이즈를 추가하는 방식이 아닌 서버에서 직접 추가하는 방식이고, 노이즈의 강도는 0.1 로 설정하였다. 집계 방식은 각 클라이언트가 가진 데이터의 비율을 고려한 가중 합산 방식인 FedAvg 알고리즘 [4]을 사용하였다.

We apply Flower's Central Differential Privacy algorithm. In this approach, noise is added on the server after aggregation. We set the noise scale to 0.1. For aggregation, we use FedAvg [4], which computes a weighted sum of client updates based on each client's proportion of data.

4.3.3. Client

각 클라이언트는 할당된 의료 데이터를 바탕으로 로컬 환경에서 독립적으로 학습을 진행한다. 각 로컬 모델은 학습률 : $1e-3$, 배치 크기 : 64, LoRA-FA alpha : 16, LoRA-FA rank : 32, Max_length : 2048 에서 최적화를 수행하였다. 옵티마이저는 프라이버시 보장을 위한 안정적인 노이즈 추가를 위해 기본 SGD(Stochastic Gradient Descent)를 사용하였다.

Each client trains independently in its local environment using its assigned medical data. We use the following hyperparameters: learning rate = 10^{-3} , batch size = 64, LoRA-FA α = 16, LoRA-FA rank = 32, and max_length = 2048. We use SGD (stochastic gradient descent) to support stable optimization under noise.

4.3.4. Dataset


본 연구에서는 MIMIC-IV 데이터셋을 [32] 활용하여 진단에 알맞은 약물 리스트를 예측하는 모델을 개발하고자 한다. MIMIC-IV는 미국 The Commonwealth of Massachusetts Bosten의 Beth Israel Deaconess Medical Center에서 수집된 대규모 의료 데이터셋으로, 2008년 부터 2019년 까지의 중환자실(ICU) 환자 기록을 포함하고 있다. 해당 데이터셋은 환자의 생체 신호, 투여된 약물, 입원 및 퇴원 정보 등 다양한 임상 데이터를 제공한다.

본 연구에서는 MIMIC-IV 데이터셋을 활용하여 진단 기반 약물 추천 모델을 구축하기 위해 사용할 파일을 선택하여 병합을 진행하였다. *We use the MIMIC-IV dataset [32] to develop a model that predicts a medication list appropriate for given diagnoses. MIMIC-IV is a large-scale clinical dataset collected at Beth Israel Deaconess Medical Center in Boston, Massachusetts, USA, and it includes intensive care unit (ICU) patient records from 2008 to 2019. The dataset provides diverse clinical information, including patients' vital signs, administered medications, and admission and discharge details. To build diagnosis-based medication recommendation pairs, we select and merge relevant files from MIMIC-IV.*

이에 데이터셋 내의 환자의 고유키인 환자 ID 및 입원 ID를 기준으로 환자의 신체 정보, 환자의 진단 정보, 투여된 약물 데이터를 병합하였다. 그러나 한 환자의 입원 기간에는 단일 진단이 아니라 여러 진단이 함께 기록되며, 해당 입원에 대해 처방된 약물 목록도 포함된다. 초기에는 각 진단에 적합한 약물을 1 대 1로 연결하여 처리하는 방식을 고려 하였으나, 한 진단에 대응하는 약물을 하나의 행으로 병합할 명확한 기준이 없어, 해당 방식의 적용이 어려운 것으로 판단되었다. 따라서 본 연구에서는 이를 대체하는 방법으로 해당 입원 기간 동안 기록된 모든 진단 목록과 처방된 약물 목록을 1 대 1로 연결하여 활용하였다. *We merge patient demographic information, diagnosis information, and prescribed medication data using patient ID and hospital admission ID (hadm_id). However, because a single admission often contains multiple diagnoses, MIMIC-IV does not provide a direct 1:1 mapping between a single diagnosis and a fixed prescription list. Therefore, we construct each training example by pairing the set of diagnoses recorded during an admission with the set of medications prescribed during the same admission.*

그림 5를 보면, 왼쪽은 MIMIC-IV에서 추출한 원본 데이터셋(patient.csv, omr.csv, diagnoses_icd.csv, prescriptions.csv)의 주요 필드를 요약한 것이다. 오른쪽은 해당 원본 데이터를 기반으로 전처리한 결과로, 각 환자의 개인정보(나이, 성별 등)와 생체신호, ICD 진단명을 통합해 구성한 Input_text, 그리고 해당 입력에 대응하는 처방 약물 리스트를 Response_text 형태로 변환한 예시를 나타낸다. 이 전처리된 Input-Response 쌍은 본 연구에서 LLM 기반 약물 처방 모델 학습에 사용된다. *As shown in Figure 5, the left panel summarizes the key fields of the raw datasets extracted from MIMIC-IV (patient.csv, omr.csv, diagnoses_icd.csv, and prescriptions.csv). The right panel presents an example of the preprocessing results based on these raw data, where each patient's demographic information (e.g., age and sex) and vital signs, together with ICD diagnosis names, are integrated into an Input_text, and the corresponding list of prescribed medications is converted into a Response_text. These preprocessed Input-Response pairs are used to train the LLM-based prescription medication model in this study.*

Figure 5. Original Medical Dataset and the Preprocessed Dataset Used for Model Training



여기서 정확도가 낮을 수밖에 없는 이유를 설명해야 함. 아니면 설득력이 없어짐.

이처럼 전처리 과정에서 구조적 한계가 존재한다. MIMIC-IV 데이터 구조상 단일 진단과 해당 진단에 대응하는 처방 약물을 1:1로 매칭할 수 있는 정보가 제공되지 않으며, 각 입원(hadm_id)에는 다수의 진단 코드와 다수의 약물 처방이 동시에 기록된다. 실제 임상 환경에서는 특정 진단에 대해 특정 약물이 처방되지만, 본 데이터셋에서는 이러한 진단-약물의 연결 정보를 명확하게 구분할 수 있는 키(key)가 존재하지 않는다. 따라서 본 연구에서는 입원 단위로 모든 진단 목록과 모든 처방 약물 목록을 통합하여 Input-Response 쌍을 구성하였다.

그러나 이 방식은 필연적으로 노이즈(noise)를 포함한다. 예를 들어, 처방 약물 목록에는 특정 진단 치료 목적의 약물뿐 아니라, 수액, 진통제, 조영제, 전해질 보충제, 인슐린, 프로토콜 기반 투약 등 진단과 직접적인 관련이 없는 약물도 포함된다. 이러한 약물들까지 모두 모델의 학습 대상이 되기 때문에, 모델은 각 진단에 적합한 약물을 직접적으로 학습하기 어렵고, 결과적으로 정확도 저하가 발생할 수밖에 없는 구조적 제약이 존재한다.

This preprocessing pipeline has an inherent structural limitation. In MIMIC-IV, the data schema does not provide information that enables a 1:1 mapping between a single diagnosis and the medications prescribed specifically for that diagnosis. Instead, each hospital admission (hadm_id) contains multiple diagnosis codes and multiple medication orders recorded concurrently. Although, in real clinical practice, specific medications are prescribed for specific diagnoses, the dataset does not include a clear key that disambiguates diagnosis-medication linkages. Therefore, in this study, we construct Input-Response pairs at the admission level by aggregating the full list of diagnoses and the full list of prescribed medications within the same admission. However, this approach inevitably introduces noise. For example, the medication list can include not only drugs intended to treat particular diagnoses but also medications that are not directly tied to a diagnosis, such as intravenous fluids, analgesics, contrast agents, electrolyte supplements, insulin, and protocol-driven administrations. Because all of these medications become part of the training target,


the model cannot reliably learn medications that are appropriate for each diagnosis in isolation, which constitutes a structural constraint that can ultimately reduce predictive accuracy.

더 나아가 본 데이터셋은 연합학습 환경에서 데이터셋을 분할 하기 위해 무작위로 분할해도 Non-IID 환경이 구성할 수 있지만, 보다 명확하게 Non-IID 환경을 구성하기 위해 의도적으로 나이를 기준으로 분포 차이를 유도하여 구성하였다.

연합학습 시뮬레이션을 위해 두 개의 병원(A 병원과 B 병원)을 구성하였다. 이때, 환자의 나이를 기준으로 10 대부터 90 대까지 연령대별로 분류한 후 각 연령대를 1:9 비율로 2 차 분류하여 A 병원에는 젊은 층이, B 병원에는 노인층이 더 많이 분포하도록 분할하였다. To construct a clearer non-IID environment, we create differences in age distribution across hospitals. We simulate two hospitals (Hospital A and Hospital B). We group patients by age from their 10s to their 90s and then split each age group into two subsets with a 1:9 ratio. Hospital A contains relatively more younger patients while Hospital B contains relatively more older patients, thereby inducing distributional heterogeneity.

Figure 6

. Age distribution difference graph of the split dataset



다음과 같은 데이터 처리 단계를 거쳤다.

1. 데이터 전처리: 모델 학습을 위한 일관된 데이터셋을 구성하기 위해 환자의 개인정보와 진단을 결측치 처리, 중복 제거, 이상치 처리 등의 전처리 작업을 수행하였다.
2. 데이터 병합 : 한 환자의 입원을 기준으로 입원당시 받은 진단 목록과 입원했을 때 처방 받은 약물 목록을 하나로 병합하였다.
3. 병원 분할: 연합 학습 시뮬레이션을 위해 2 개의 병원으로 구성 하였으며, 데이터셋 크기와, 연령층의 분포 차이를 두어 데이터 불균형을 유도하였다.
4. 입력 데이터 변환: 최종적으로 정제된 데이터를 1-8B-Instruct 모델에 입력할 수 있도록 모델의 프롬프트 형식에 맞춰 변환하였다.

We follow these data-processing steps:

1. Data preprocessing: handle missing values, remove duplicates, and treat outliers to build a consistent dataset for training.
2. Data merge: merge diagnosis lists and prescription medication lists per admission.
3. Hospital split: split into two hospitals and induce imbalance in dataset size and age distribution to reflect non-IID.
4. Input conversion: convert the cleaned dataset into the prompt format expected by the Llama3.1-8B-Instruct model.

4.4. Experimental Results and Disussion

연합학습의 성능을 검증하기 위해 단일 노드에서 전체 데이터를 활용하여 학습한 모델과의 비교를 수행하였다. 구체적으로, (1) 단일 노드에서 전체 데이터를 활용한 성능 평가, (2) 연합학습을 통해 각 병원 단위로 수행한 평가, (3) 최적의 정확도를 기준으로 연합학습 모델과 단일 모델을 비교하는 과정을 통해 성능을 확인하였다. To validate the performance of federated learning, we compare it with a model trained on a single node using the entire dataset. Specifically, we evaluate: (1) performance when training on a single node with all data, (2) performance under federated learning with training conducted separately at each hospital, and (3) performance by comparing the federated model with the single-node model based on the best achieved accuracy.

4.4.1. Accuracy in Single Learning

Table 2. This table shows the accuracy results of evaluating the saved model at each step after setting the rank value of FFA-LoRA to 32, epoch 10, and batch size to 4 during the single model learning process.

Rank	Step	출력률	정확도
32	852	100%	19.3%
	1704	95%	20.5%
	2556	90%	23.7%
	3408	95%	21.5%
	4260	95%	20.5%
	5112	90%	24.8%
	5964	65%	24.5%
	6816	45%	21.3%
	7668	35%	21.7%
	8520	35%	18.3%

실험 결과, 출력률은 step 이 진행됨에 따라 100%에서 35%까지 점차 감소하는 경향을 보였으며, 이는 학습이 진행될수록 모델이 질문에 응답을 하는 비율이 줄어들고 있음을 확인했다.

정확도의 경우 step 5112 에서 24.8%로 가장 높은 값을 기록했으며, step 5964 에서도 24.5%로 비교적 높은 정확도를 보였다. 반면, 학습 초반인 step 852 에서는 19.3%로 가장 낮으며 학습을 많이 할 수록 step8520 는 18.3%로 정확도가 떨어지는 것을 확인했다. 이는 학습 초반과 후반 보다는 중간 단계에서 상대적으로 안정적이고 높은 정확도를 보였음을 의미한다. As training progressed, the output rate gradually decreased from 100% to 35%, indicating that the proportion of questions for which the model produced an answer declined over time. In terms of accuracy, the highest value was observed at step 5112 (24.8%), and step 5964 also achieved a relatively high accuracy of 24.5%. In contrast, accuracy was lowest at step 852 (19.3%) in the early stage of training, and it decreased to 18.3% at step 8520 after further training. These results suggest that accuracy was relatively more stable and higher during the mid-training phase than in the early or late stages.

정확도와 적합성 간의 차이가 상당히 두드러졌다. 정확도에 비해 적합성이 압도적으로 높은 이유는, 학습된 LLM(대형 언어 모델)이 질병에 알맞은 약물을 추천하면서, 하나의 성분을 띄는 약물에 대해 여러 약물을 추천한다. 예를 들어,

통증을 완화 시키기 위한 동일한 성분의 약물을 여러개 추천하는 경우가 있다. 하지만 실제 정답 데이터셋에서는 그 중 하나의 약물만 처방되었기 때문에, 모델이 추천한 여러 약물 중 하나만 정답으로 간주되며, 이로 인해 정확도가 낮게 측정되는 경향이 있다. We also observe a gap between measured accuracy and clinical appropriateness. If the model recommends multiple clinically plausible medications, the evaluation may still count only one medication as correct depending on the ground-truth list, yielding a lower list-matching accuracy.

또한, 본 연구에서 사용 중인 Llama3.1-8B-Instruct [25] 모델은 의료 지식에 대한 사전 학습이 어느 정도 되어 있어, 학습되지 않은 약물이라도 진단에 적합하다고 판단되면 이를 추천하는 경향을 보였다. 그러나 실제 정답 데이터셋에서는 동일한 성분을 가진 약물 중 하나만 정답으로 처리되기 때문에, 모델이 여러 약물을 추천하더라도 그 중 하나만 정답으로 인정되어 정확도가 낮게 측정되는 문제가 발생한다. In addition, the Llama3.1-8B-Instruct model used in this study [25] may already encode some relevant medical knowledge, and we observed cases where it recommended medications that appeared appropriate for a diagnosis even when those medications were not present in the fine-tuning dataset. However, in the ground-truth dataset, only one medication is treated as the correct among medications with the same active ingredient. As a result, even when the model recommends multiple clinically reasonable medications (based on our GPT-based review), only one of them is counted as correct, which can lead to an underestimation of accuracy.

결론적으로, FFA-LoRA [12] rank 32 실험에서는 step 5112 및 5964 부근에서 가장 높은 정확도를 기록했으며, 이는 학습 중간 단계에서 모델이 가장 효과적으로 수렴했음을 보여준다. In the FFA-LoRA [12] experiment with rank 32, the highest accuracy was observed around steps 5112 and 5964, suggesting that the model converged most effectively during the mid-training phase.

추가적으로, 본 연구에서는 표에 제시되지는 않았지만, 각 샘플의 응답을 의료 지식을 가지고 있는 LLM 모델인 GPT 로 평가했을 때 평균적으로 약 90%는 임상적으로 타당한 약물로 판단되었다. 이는 본 모델이 의료진을 대체하기보다는 보조적인 역할을 수행할 수 있음을 시사한다. 모델이 제안하는 약물이 임상적으로 부적절하다면 해당 추천은 무효화되었지만, 임상적으로 적절하다고 평가되는 경우에는 의료진이 이를 참고하여 최종 의사결정을 내리는 데 도움을 줄 수 있을 것으로 기대된다. In addition, although not reported in the table, when we asked GPT, an LLM with medical knowledge, to evaluate the responses for each sample, approximately 90% of the recommended medications were judged to be clinically valid on average. This suggests that the proposed model is more suitable as an assistive tool rather than a replacement for clinicians. If a recommended medication is clinically inappropriate, the recommendation would be discarded. If it is deemed clinically appropriate, clinicians may use it as a reference to support final decision-making.

이러한 결과는 Goh et al. (2024)이 보고한 바와 같이 LLM 이 임상주의 진단 추론 과정에 긍정적인 영향을 미칠 수 있다는 점과 일맥상통한다 [33]. 따라서 본 모델은 의료진을 대체하기보다는 보조적 의사결정 지원 도구로서의 활용 가능성을 보여주며, 실제 임상 적용을 위해서는 환자 특이성을 고려한 안전장치와 추가적 검증 연구가 필요하다. These findings are consistent with the report by Goh et al. (2024) that LLMs can positively influence clinicians' diagnostic reasoning processes [33]. Therefore, our model demonstrates the potential to serve as a supportive clinical decision aid rather than replacing medical professionals, while practical deployment will require additional safeguards that account for patient-specific factors and further validation studies.

4.4.2. Performance of Federated Learning

연합학습을 도입하기 위해 전 각 모델은 단일 모델에서와 동일한 모델 환경에서 연합학습을 진행하였다. 데이터셋을 분할된 A,B 로 두 병원을 가정으로, FedAVG [4]를

기반으로 총 10 라운드 학습을 수행하였다. 연합학습의 특성상 최종 라운드의 모델은 집계가 이루어진 후 저장되므로, 실험에서는 라운드 9까지의 모델을 저장하여 각 라운드 별 성능을 평가하였다. 각 모델은 해당 라운드에서 저장된 가중치를 불러와 데이터셋 각각의 test dataset 를 입력으로 평가하였다. To incorporate federated learning, we conduct training under the same model configuration as in the single-node setting. We simulate two hospitals (Hospital A and Hospital B) using the split datasets and train for a total of 10 rounds based on FedAvg [4]. Because the global model is saved after aggregation at the end of each round in federated learning, we save the aggregated global models from rounds 1 through 9 and evaluate each round on the test datasets.

Table 3. This table shows the accuracy evaluated using the test dataset of Hospital A divided into the federated learning model.

Rank	Dataset	Round	출력률	정확도
32	A	1	100%	21.7%
		2	100%	18.8%
		3	100%	19.5%
		4	100%	20.2%
		5	100%	24.2%
		6	100%	20.3%
		7	100%	20.0%
		8	100%	21.5%
		9	100%	21.3%

Table 4. This table shows the accuracy evaluated using the test dataset of Hospital B divided into the federated learning model.

Rank	Dataset	Round	출력률	정확도
32	B	1	100%	23.2%
		2	100%	24.0%
		3	100%	23.8%
		4	100%	21.6%
		5	100%	20.5%
		6	100%	23.0%
		7	100%	21.6%
		8	100%	21.3%
		9	100%	23.1%

실험 결과, 데이터셋 A에서는 라운드 2,3을 제외하고는 약 20%를 넘는 정확도로 유사한 정확도를 확인하였으며, 라운드 5에서 24.2%로 가장 좋은 정호확도를 보였다. 데이터셋 B에서는 전반적으로 데이터셋 A 보다 높은 정확도로 확인하였으나 약

20~24 로 유사한 성능을 유지하는 것으로 확인하였으며, 라운드 2 에서 24.0%으로 가장 높은 정확도를 달성하였다

결과적으로, 단일 모델과 비교하였을 때 약 19~24 로 유사한 성능이 나타나는 것을 확인하였다. 이는 연합학습이 데이터 분할 환경에서도 성능 저하 없이 안정적으로 수렴할 수 있으며, 특정 데이터셋에서는 단일 모델 대비 성능 향상을 가져올 수 있음을 보여준다. In dataset A, accuracy was generally above 20% across rounds, except for rounds 2 and 3, and the best accuracy was achieved at round 5, with 24.2%. In dataset B, accuracy was overall higher than in dataset A and remained within a similar range, at approximately 20–24%, with the highest accuracy achieved at round 2 at 24.0%. Compared with the single-model baseline, federated learning achieved comparable performance, at approximately 19–24%, suggesting that it can converge stably without noticeable performance degradation under a data-partitioned setting and may even improve performance for certain datasets.

4.4.3 Comparison between Single and Federated Learning

Table 5. This table shows the results of comparing the output rate and accuracy based on the highest performance when performing single learning (Single) and federated learning (FL) respectively.

Learning Method	Dataset	출력률	정확도	Avg	Difference
Single	Full	90%	24.8%	-	-
	A	75%	22.9%	23.0%	0.2%
	B	95%	23.1%		
FL	Full	100%	23.6%	-	-
	A	100%	24.2%	24.1%	0.2%
	B	100%	24.0%		

단일 학습의 경우, Full dataset 에서 24.8%의 정확도를 기록하였으며, 데이터셋을 A 와 B 로 분할하여 개별적으로 평가했을 때는 각각 22.9%와 23.1%의 정확도를 나타냈다. 이때 두 데이터셋의 결과를 평균한 값은 23.0%로 집계되었다. In the single-training setting, the model achieved an accuracy of 24.8% on the full dataset. When the dataset was split into A and B and evaluated separately, the accuracies were 22.9% and 23.1%, respectively, yielding an average accuracy of 23.0% across the two subsets.

반면 연합학습에서는 Full dataset 에서 23.6%의 정확도를 기록하여 단일 학습 대비 다소 낮은 성능을 보였다. 그러나 데이터셋을 A 와 B 로 분리하여 평가했을 때는 각각 24.2%와 24.0%의 정확도를 달성하여 단일 학습 결과를 상회하였다. 평균 정확도 또한 24.1%로 산출되어, 단일 학습 평균 정확도인 23.0%보다 약 1.1% 높은 결과를 확인할 수 있었다. In contrast, under federated learning, the model achieved 23.6% accuracy on the full dataset, which is slightly lower than single training. However, when evaluated separately on datasets A and B, federated learning achieved accuracies of 24.2% and 24.0%, respectively, exceeding the corresponding single-training results. The average accuracy under federated learning was 24.1%, which is approximately 1.1 % higher than the single-training average of 23.0%.

추가적으로 주목할 점은, 단일 학습과 연합학습 모두에서 데이터셋 A 와 B 간의 성능 차이가 0.2%로 유사하게 유지되었다는 것이다. 단일 학습은 A 와 B 를 합쳐진 Full dataset 으로 학습을 진행한 반면, 연합학습은 두 데이터셋을 분할하여 독립적으로

학습한 뒤 FedAVG [4]를 통해 집계하는 방식으로 수행되었다. 그럼에도 불구하고 A 와 B 간의 성능 격차가 유사하게 유지되었다는 사실은, 연합학습이 데이터 분할 구조로 인해 발생할 수 있는 잠재적 불안정성에도 불구하고 성능 차이를 최소화하면서 안정적으로 학습이 이루어졌음을 의미한다. 이는 연합학습이 데이터 분할 환경에서조차 단일 학습과 유사한 일관성을 확보할 수 있음을 시사한다. **Notably, in both single training and federated learning, the performance gap between datasets A and B remained similarly small at 0.2%. Single training was performed by training on the combined full dataset, whereas federated learning was performed by training independently on the split datasets and then aggregating the updates via FedAvg [4]. Despite this difference, the fact that the A–B performance gap remained similar suggests that federated learning trained stably while minimizing inter-dataset disparity, even under a data-partitioned setting. This indicates that federated learning can maintain consistency comparable to single training even when data are distributed across clients.**

따라서 단일 학습은 Full dataset 에서 더 높은 성능을 보였으나, 연합학습은 분할된 데이터셋 환경에서 일관되게 더 높은 정확도를 기록하였다. 이러한 결과는 연합학습이 데이터가 분산된 환경에서도 성능 저하 없이 학습을 진행할 수 있을 뿐 아니라, 경우에 따라 단일 학습 대비 성능 향상을 가져올 수 있음을 보여주는 근거가 된다. **In summary, federated learning consistently achieved higher accuracy in the split-dataset evaluations, whereas single training performed better on the full dataset. These results provide evidence that federated learning can be trained effectively without performance degradation in distributed-data settings and, in some cases, can yield performance improvements over single training.**

4.4.4 Comparison of Baseline Model and Federated Learning for Single Diagnosis

이전 실험에서는 다중 진단 환경에서의 처방 약물 정확도를 평가한 반면, 본 실험에서는 단일 진단 상황에 초점을 맞추어 처방 약물의 정확도를 보다 정밀하게 분석하였다. 이를 통해 진단 수 증가로 인해 발생하는 복잡성의 영향을 배제하고, 개별 질환에 대해 모델이 선택한 약물의 적절성을 보다 명확히 평가하고자 하였다.

또한 제안한 방법의 성능 향상을 검증하기 위해 base model 과 실험 모델 간 비교 실험을 수행하였다. 두 모델은 동일한 데이터셋과 평가 기준을 기반으로 처방 정확도를 측정함으로써, 단일 진단 환경에서의 성능 차이와 개선 효과를 객관적으로 비교·분석하였다. **In the previous experiment, we evaluated prescription accuracy under a multi-diagnosis setting, whereas here we focus on a single-diagnosis scenario to enable a more fine-grained analysis. By reducing the complexity introduced by multiple concurrent diagnoses, we can more clearly assess whether the model selects appropriate medications for an individual condition. To verify the performance gains of the proposed approach, we compare the base model and the experimental model under the same dataset and evaluation criteria, and measure prescription accuracy to objectively analyze performance differences and improvements in the single-diagnosis setting.**

모델이 생성한 처방 결과에 대해서는 GPT 기반 평가 모델을 활용하여 각 약물이 해당 환자 정보와 진단에 비추어 적합한지 여부를 판단하였으며, 이를 통해 임상적 맥락을 고려한 처방 적합성 평가를 수행하였다. **For the prescriptions generated by the model, we additionally use a GPT-based evaluator to assess whether each medication is appropriate given the patient information and diagnosis. This enables an evaluation of prescription suitability that accounts for clinical context.**

Table 6. Comparison of Baseline Model and Federated Learning for Single Diagnosis

Model	출력률	정확도
Base	39%	61.5%

FL	79%	58.2%
본 실험 결과, 연합학습(Federated Learning, FL) 모델은 베이스 모델에 비해 처방 약물 출력률이 39%에서 79%로 크게 향상되었음을 확인하였다. 이는 진단 입력에 대해 처방을 회피하던 베이스 모델과 달리, FL 모델이 훨씬 더 많은 경우에서 처방 결정을 시도함을 의미하며, 시스템의 활용 가능성을 크게 높인 결과로 해석할 수 있다. 이러한 출력률의 차이는 정확도 지표를 해석하는 방식에도 영향을 미친다. 정확도만을 기준으로 평가할 경우 베이스 모델이 더 높은 성능을 보이는 것처럼 보일 수 있다. 그러나 베이스 모델은 처방 출력률이 39%의 낮은 수치를 보여주고 있고, 해당 정확도는 낮은 출력률 결과에 기반한 값이다. 반면, 연합학습 모델은 출력률을 79%까지 확대하면서도 출력 대비 정확도를 58.2%의 결과를 보여주고 있으므로 상대적으로 보았을 때 베이스 모델의 정확도보다 낮은 수치가 아니다. <i>The experimental results show that the federated learning (FL) model substantially increased the prescription output rate from 39% to 79% compared with the base model. This suggests that the FL model attempts to provide a prescription for a much larger fraction of diagnosis inputs, whereas the base model often avoids making a prescription decision, thereby improving the practical usability of the system. This difference in output rate also affects how the accuracy metric should be interpreted. If accuracy alone is considered, the base model may appear to perform better, but its accuracy is computed over a much smaller set of answered cases due to its low output rate (39%). In contrast, the FL model achieves an accuracy of 58.2% while producing outputs for 79% of inputs, indicating that its performance is not inferior to the base model when output coverage is taken into account.</i> 출력된 연합학습의 정확도는 58.2%로 이전의 다중 진단 입력 실험 결과(표 5)와 비교했을 때, 단일 진단 입력 환경에서는 전체 정확도가 약 20% 향상된 것으로 나타났다. 이는 실제 의료 환경에서 의료진이 주로 하나의 주요 진단명을 기반으로 처방을 고려하는 상황을 반영한 결과로, 본 연구에서 설정한 단일 진단 기반 평가가 임상적 현실성을 충분히 갖추고 있음을 시사한다. <i>Moreover, the FL model's accuracy of 58.2% is approximately 20 percentage points higher than the result from the previous multi-diagnosis experiment, as shown in Table 5, indicating that the single-diagnosis setting yields substantially better overall accuracy. This aligns with typical clinical practice, where clinicians often consider prescriptions primarily based on a single principal diagnosis, and suggests that the single-diagnosis evaluation used in this study is clinically more realistic.</i>		

5. Conclusion

본 연구는 의료 데이터를 기반으로 환자의 진단에 적합한 처방 약물을 추천하여 의료진의 의사결정을 지원하는 시스템을 개발하였다. 이를 위해 LLM(Llama3.1-8B-Instruct)에 FFA-LoRA [12]와 FlashAttenti-2 [16]을 적용한 단일 학습 모델과, 동일한 모델 구조를 바탕으로 Flower 프레임워크의 FedAvg를 활용한 연합학습 [4] 모델을 비교·분석하였다. 특히, 연합학습에서는 두 병원을 가정하여 데이터를 분할하였고, 연령대 분포에 차이를 부여함으로써 실제 임상 환경에서 발생할 수 있는 Non-IID 조건을 반영하였다. *This study develops a system that supports clinicians' decision-making by recommending prescription medications appropriate for a patient's diagnoses based on clinical data. We compare and analyze a single-model training model that applies FFA-LoRA [12] and FlashAttention-2 [16] to an LLM backbone (Llama3.1-8B-Instruct) and a federated learning model built on the same architecture using FedAvg in the Flower framework [4]. In particular, for federated learning, we simulate two hospitals by splitting the dataset and inducing differences in age distributions to reflect Non-IID conditions that may arise in real clinical settings.*

실험 결과, 단일 학습에서는 학습 중간 단계(step 5112)에서 정확도 24.8%로 가장 높은 성능을 기록하였다. 다만 모델이 동일한 효능을 가진 여러 약물을 동시에 추천하는 경우, 정답 데이터셋에서는 그중 하나만 정답으로 간주되기 때문에 정확도가 낮게 측정되는 경향이 나타났다. 반면, 연합학습에서는 분할된 데이터셋으로 학습을 수행했을 때 A 데이터셋에서 24.2%, B 데이터셋에서 24.0%의 정확도를 기록하며 일관된 성능 향상을 확인하였다. 최종적으로 단일 학습 평균 정확도(23.0%)와 연합학습 평균 정확도(24.1%)를 비교했을 때, 연합학습이 1.1% 더 높은 성능을 달성하였다. 또한 데이터셋 A 와 B 간의 정확도 차이는 단일 학습과 연합학습 모두에서 0.2%로 동일하게 유지되어, 학습 방식의 변화에도 상대적 성능 격차가 안정적으로 보존됨을 확인하였다. 반면 Full dataset 을 기준으로 단일 학습(24.8%)이 연합학습(23.6%)보다 높은 성능을 보였으며, 이는 데이터가 집중된 환경에서는 단일 학습이 유리하지만, 분산 환경에서는 연합학습의 실용적 이점이 부각됨을 보여준다. In the experiments, the single-model training achieved its best accuracy of 24.8% at a mid-training step (step 5112). However, when the model recommends multiple medications with the same active ingredient, the ground-truth dataset treats only one of them as correct, which tends to underestimate accuracy. In contrast, under federated learning trained on the split datasets, we observed consistent performance improvements, achieving accuracies of 24.2% on dataset A and 24.0% on dataset B. Thus, federated learning achieved a higher average accuracy (24.1%) than single training (23.0%). Moreover, the accuracy gap between datasets A and B remained identical at 0.2% under both single and federated training, indicating that the relative performance difference was stably preserved despite the change in training scheme. When evaluated on the full dataset, however, single training (24.8%) outperformed federated learning (23.6%), suggesting that centralized training can be advantageous when data are concentrated, whereas federated learning offers practical benefits in distributed scenarios.

이전 실험에서는 다중 진단 환경에서의 처방 정확도를 평가하였으나, 본 연구에서는 추가적으로 단일 진단 상황에 초점을 맞추어 진단 수 증가로 인해 발생하는 복잡성의 영향을 배제하고, 개별 질환에 대해 모델이 선택한 약물의 적절성을 보다 정밀하게 분석하였다. 그 결과, 실험 모델은 베이스 모델 대비 처방 출력률 약 두배가량 크게 향상시켰으며, 특히 단일 진단 환경에서는 다중 진단 환경과 비교하여 정확도가 약 20% 개선되는 성능 향상을 보였다. We additionally evaluated a single-diagnosis setting to reduce the complexity introduced by multiple concurrent diagnoses and to assess prescription appropriateness for individual conditions more precisely. In this single-diagnosis experiment, the FL model approximately doubled the prescription output rate compared with the baseline model. It also improved accuracy by about 20 % relative to the multi-diagnosis setting.

의미하는 바는 명확하다. (1) 분산 환경에서도 성능 저하 없이 오히려 데이터가 분할된 현실적 조건에서 성능 이득을 기대할 수 있다. (2) 연령 분포가 상이한 non-IID 조건에서도 A-B 간 격차가 일정하게 유지되어 수렴의 안정성이 검증되었다. (3) 사람 평가 기준으로 살펴보았을 때 정확도가 낮아 보이는 경향이 있으나, 모델이 내놓은 답변은 의료에서 좋은 성능의 띄는 LLM 을 통해 전부 확인해 본 결과 대부분 의료적으로 타당한 것으로 확인되었다. (4) 단일 진단을 기반으로 평가한 경우 모델 처방 성능이 유의미하게 향상되었으며, 이는 실제 의료 환경을 보다 잘 반영한 평가 설정의 효과로 확인 하였다. These results suggest the following. (1) Even in distributed scenarios, federated learning can yield performance gains under realistic data partitioned conditions without degradation. (2) Under Non-IID conditions with different age distributions, the A-B performance gap between two hospitals remains consistent, providing evidence of stable convergence. (3) Although the automatic metric can make accuracy appear low, a separate GPT-based review of the generated prescriptions indicates that most recommendations are clinically plausible. (4) When evaluated under a single-diagnosis setting, prescription performance

improves considerably, enabling a clearer assessment of medication appropriateness for an individual condition.

따라서 이 모델은 의료진의 결정을 대신하는 것이 아니라, 의료진이 판단을 내릴 때 참고할 수 있는 유용한 도구가 될 수 있다. 즉, 부적절한 약물 추천은 쉽게 걸러낼 수 있고, 적절한 추천은 의료진이 더 나은 결정을 내리는 데 도움을 줄 수 있다. This model is not intended to replace clinicians. Instead, it can serve as a practical decision-support tool. Inappropriate medication suggestions can be readily filtered out, while appropriate recommendations may help clinicians make better-informed final decisions.

향후 연구에서는 첫째, 더 많은 서버 환경을 구성하여 확장성을 검증하고, 둘째, 한국 기반의 의료 데이터셋을 활용하여 적용 가능성을 높이며, 셋째, 의학 전문가의 검증을 통해 임상적 신뢰도를 강화할 계획이다. 또한 넷째, 개인정보 보호 강화를 위해 차등 프라이버시 외의 다양한 보안 기법을 추가적으로 탐구하고, 마지막으로 FedAvg 이외의 연합학습 알고리즘을 적용하여 최적의 학습 전략을 모색할 예정이다. 이를 통해 본 연구는 환자 개인정보 보호와 효율적인 모델 학습을 동시에 달성할 수 있는 실질적 의료 AI 시스템으로 발전할 것으로 기대한다. In future work, we will validate scalability by simulating a larger number of server–client environments. We will also improve applicability by using Korean-based clinical datasets and strengthen clinical reliability through evaluation by clinicians. In addition, we will explore security mechanisms beyond differential privacy to further enhance privacy protection. Finally, we will investigate federated learning algorithms beyond FedAvg to identify more effective training strategies. Through these efforts, we aim to advance this work toward a practical medical AI system that can protect patient privacy while enabling efficient model training.

References

1. Peoples Dispatch. South Korea Health Workers Demand Sustainable Staffing Policies. Peoples Dispatch, 24 July 2025. Available online: <https://peoplesdispatch.org/2025/07/24/south-korea-health-workers-demand-sustainable-staffing-policies/> (accessed on 30 September 2025).
2. Boniol, M.; Kunjumen, T.; Nair, T.S.; Siyam, A.; Campbell, J.; Diallo, K. The Global Health Workforce Stock and Distribution in 2020 and 2030: A Threat to Equity and “Universal” Health Coverage? *BMJ Glob. Health* 2022, 7(6), e009316. <https://doi.org/10.1136/bmjgh-2022-009316>.
3. Jeong, J.; Kim, S.; Pan, L.; Hwang, D.; Kim, D.; Choi, J.; Kwon, Y.; Yi, P.; Jeong, J.; Yoo, S.J. Reducing the Workload of Medical Diagnosis through Artificial Intelligence: A Narrative Review. *Medicine (Baltimore)* 2025, 104(6), e41470. <https://doi.org/10.1097/MD.00000000000041470>.
4. McMahan, B.; Moore, E.; Ramage, D.; Hampson, S.; y Arcas, B.A. Communication-Efficient Learning of Deep Networks from Decentralized Data. In *Proceedings of the 20th International Conference on Artificial Intelligence and Statistics (AISTATS)*; PMLR: Fort Lauderdale, FL, USA, 2017; pp. 1273–1282.
5. Zhang, L.; Hang, Y.; Han, S.; Chen, X.; Xu, Z. LoRA-FA: Memory-Efficient Low-Rank Adaptation for Large Language Models Fine-Tuning. *arXiv Preprint arXiv:2308.03303*, 2023.
6. Kim, S.H.; Park, H.; Lee, H. PANCDR: Precise Medicine Prediction Using an Adversarial Network for Cancer Drug Response. *Bioinformatics* 2024, 25(2), bbae088.
7. Park, J.C.; Lee, J.M.; Byun, J.M. ML-Based Sequential Analysis to Assist Selection between VMP and RD for Newly Diagnosed Multiple Myeloma. *npj Precis. Oncol.* 2023, 7, 46.
8. Kim, Y.H.; Choi, J.Y.; Choi, H.J.; Choi, R.W.; Park, R.W.; Rhie, S.J. Translation of Machine Learning-Based Prediction Algorithms to Personalised Empiric Antibiotic Selection: A Population-Based Cohort Study. *J. Antimicrob. Agents* 2023, 62(5), 106966.

9. Mukherjee, P.; Humbert-Droz, M.; Chen, J.H.; et al. SCOPE: Predicting Future Diagnoses in Office Visits Using Electronic Health Records. *Sci. Rep.* **2023**, *13*, 11005. <https://doi.org/10.1038/s41598-023-38257-9>. 1215
1216
10. Choi, E.; Bahadori, M.T.; Schuetz, A.; Stewart, W.F.; Sun, J. Doctor AI: Predicting Clinical Events via Recurrent Neural Networks. In *Proceedings of the Machine Learning for Healthcare Conference*; PMLR: Los Angeles, CA, USA, 2016; pp. 301–318. 1217
1218
11. Lee, H.Y.; Jeong, M.H.; Kim, M.E.; Lim, D.H.; Kim, Y.W.; Han, Y.W.; Kim, Y.W.; Choi, J.H.; Kim, S.H. Trends of Clinical Decision Support System (CDSS). *J. Biomed. Inform. Res.* **2016**, *31*(4), 77–85. 1219
1220
12. Sun, Y.; Li, J.; Chen, T.; et al. Improving LoRA in Privacy-Preserving Federated Learning. *arXiv Preprint arXiv:2403.12313*, 2024. 1221
13. Hu, E.J.; Shen, Y.; Wallis, P.; Allen-Zhu, Z.; Li, Y.; Wang, L.; Chen, W. LoRA: Low-Rank Adaptation of Large Language Models. In *Proceedings of the International Conference on Learning Representations (ICLR)*; 2022. 1222
1223
14. Dettmers, T.; Lewis, M.; Belkada, Y.; Zettlemoyer, L. QLoRA: Efficient Finetuning of Quantized LLMs. In *Advances in Neural Information Processing Systems (NeurIPS)*; 2023; pp. 10088–10115. 1224
1225
15. Liu, S.-Y.; et al. DoRA: Weight-Decomposed Low-Rank Adaptation. In *Proceedings of the 41st International Conference on Machine Learning (ICML)*; 2024. 1226
1227
16. Dao, T. FlashAttention-2: Faster Attention with Better Parallelism and Work Partitioning. *arXiv Preprint arXiv:2307.08691*, 2023. 1228
1229
17. Zhu, Z.; Liu, S.; Han, S. Deep Leakage from Gradients. In *Advances in Neural Information Processing Systems (NeurIPS)*; 2019; Vol. 32. 1230
1231
18. Lee, J. Federated Learning Technology Trends and Industrial Implications. In *Proceedings of the Annual Conference of the Korea Information Processing Society (KIPS)*; 2020. 1232
1233
19. Shan, J.; et al. Differential Privacy Federated Learning: A Comprehensive Review. *J. Adv. Comput. Sci. Appl.* **2024**, *15*(7). 1234
20. Dwork, C. Differential Privacy: A Survey of Results. In *Proceedings of the International Conference on Theory and Applications of Models of Computation*; Springer: Berlin/Heidelberg, Germany, 2008; pp. 1–19. 1235
1236
21. Zheng, X.; et al. Safely Learning with Private Data: A Federated Learning Framework for Large Language Models. *arXiv Preprint arXiv:2406.14898*, 2024. 1237
1238
22. Kurakin, A.; et al. Harnessing Large-Language Models to Generate Private Synthetic Text. *arXiv Preprint arXiv:2306.01684*, 2023. 1239
23. Park, Y. Utilization of Online Pharmaceutical Prescription Information in Europe and Japan: Implications. *Int. Soc. Secur. Rev.* **2024**, *30*, 115–124. 1240
1241
24. Dao, T.; Fu, D.; Li, X.; et al. FlashAttention: Fast and Memory-Efficient Exact Attention with IO-Awareness. In *Advances in Neural Information Processing Systems (NeurIPS)*; 2022; Vol. 35, pp. 16344–16359. 1242
1243
25. Touvron, H.; et al. LLaMA: Open and Efficient Foundation Language Models. *arXiv Preprint arXiv:2302.13971*, 2023. 1244
26. Zhu, H.; Liu, Z.; Han, S. Federated Learning on Non-IID Data: A Survey. *Neurocomputing* **2021**, *465*, 371–390. 1245
27. Tang, Z.; Li, M.; Jiang, Y.; Zhang, T.; Yang, Q. Virtual Homogeneity Learning: Defending against Data Heterogeneity in Federated Learning. In *Proceedings of the International Conference on Machine Learning (ICML)*; PMLR, 2022. 1246
1247
28. Lee, K.; et al. Research on Federated Learning with Differential Privacy. In *Proceedings of the Annual Conference of the Korea Information Processing Society (KIPS)*; 2024. 1248
1249
29. Muthukrishnan, S.; Kalyani, S. Grafting Laplace and Gaussian Distributions: A New Noise Mechanism for Differential Privacy. *IEEE Trans. Inf. Forensics Secur.* **2023**, *18*, 5359–5374. 1250
1251
30. Flower. Differential Privacy in Flower. Available online: <https://flower.ai/docs/framework/explanation-differential-privacy.html> (accessed on 11 September 2025). 1252
1253
31. Beutel, D.J.; Topal, T.; Mathur, A.; Qiu, X.; Parcollet, T.; de Gusmão, P.P.B.; Lane, N.D. Flower: A Friendly Federated Learning Research Framework. In *Proceedings of the 29th ACM International Conference on Multimedia (MM '21)*; Chengdu, China, 20–24 October 2021; ACM: New York, NY, USA; pp. 2503–2506. <https://doi.org/10.1145/3474085.3479210>. 1254
1255
1256
32. Johnson, A.E.W.; Bulgarelli, L.; Shen, L.; et al. MIMIC-IV, a Freely Accessible Electronic Health Record Dataset. *Sci. Data* **2023**, *10*, 1. 1257
<https://doi.org/10.1038/s41597-022-01899-x>. 1258

33. Goh, E.; Gallo, R.; Hom, J.; et al. Large Language Model Influence on Diagnostic Reasoning: A Randomized Clinical Trial. JAMA Netw. Open 2024, 7(10), e2440969. <https://doi.org/10.1001/jamanetworkopen.2024.40969>.

Disclaimer/Publisher’s Note: The statements, opinions and data contained in all publications are solely those of the individual author(s) and contributor(s) and not of MDPI and/or the editor(s). MDPI and/or the editor(s) disclaim responsibility for any injury to people or property resulting from any ideas, methods, instructions or products referred to in the content.